



RESUMO DE ESTATÍSTICA DESCRITIVA & VISUALIZAÇÃO DE DADOS

1 Check-list da Análise Exploratória de Dados

OBSERVAÇÃO: tente obter informações de um especialista na área do domínio da aplicação para estas etapas.

1. Crie uma cópia dos dados para iniciar a análise exploratória (reduzindo-os para um tamanho gerenciável, se necessário);
2. Crie um Notebook Jupyter para manter um registro da sua análise exploratória de dados;
3. Analise cada atributo e suas características:
 - (a) Nomes das variáveis/*features*;
 - (b) Tipo de dado (categórico, texto, ou numérico, *int/float*, limitado/ilimitado, estruturado, etc...);
 - (c) Veja o percentual de de valores ausentes (do inglês, *missing values*) e trate-os de acordo com uma das opções:
 - Preencha os valores ausentes com imputação de dados via média, mediana ou moda;
 - Exclusão das linhas/registros do conjunto de dados que possuem valores ausentes;
 - Exclusão da coluna/*features* do conjunto de dados que possuem valores ausentes, para isso, antes, analise a importância da *feature* e se ela não fará falta para solução do problema;
 - (d) Nível de ruído e tipo de ruído (erros de arredondamento, erros de registro, por exemplo, registros com mais atributos do que as colunas da estrutura do arquivo);
4. Para tarefas de Aprendizado de Máquina Supervisionado, identifique a(s) variável(eis) alvo, i.e. variável dependente;
5. Sumarize os dados por meio de medidas de estatística descritiva;
6. Visualize os dados e identifique o tipo de forma da distribuição (*right-skewed*, *left-skewed*, caudas pesadas ou multimodal);
7. Identifique possíveis *outliers* nas observações e analise a possibilidade de remoção;
8. Compare a estatística descritiva com os gráficos gerados na etapa de visualização de dados;
9. Identifique o tipo de relacionamento entre as variáveis ou *features*;
10. Verifique as correlações entre as variáveis ou *features*;
11. Identifique as correlações fortes entre as variáveis e remova uma delas (existe critério para isso, não faça de qualquer jeito);
12. Identifique as transformações promissoras que você pode querer aplicar nas variáveis que possuem distribuições tendenciosas (*right-skewed*, *left-skewed* e multimodal);
13. Identifique dados adicionais que podem ser úteis e veja se é possível obtê-los.
14. Descreva os principais *insights* que você aprendeu e faça um relatório.



2 Diretrizes para Análise Exploratória de Dados

A seguir estão algumas perguntas para guiar a criação de gráficos durante as etapas de desenvolvimento da análise exploratória de dados:

1. Como os valores da *feature X* são distribuídos?
2. Como a *feature X* e a *feature Y* se relacionam?
3. A distribuição de dados da *feature X* é a mesma entre os subgrupos definidos pela *feature Z*?
4. Existem observações incomuns na *feature X*? Na combinação de (X, Y) ? Da *feature X* para um subgrupo da *feature Z*?

Ao responder a cada uma dessas perguntas, é importante relacionar sua resposta às *features* medidas e ao contexto. Também é importante adotar uma abordagem ativa e investigativa na análise. Para orientar suas explorações, faça perguntas do tipo “*qual o próximo passo?*” e “*qual a relevância disso?*”, como as seguintes perguntas:

- (a) *Você tem motivos para esperar que um grupo ou observação seja diferente?*
- (b) *Por que a sua descoberta sobre a forma da distribuição dos dados pode ser relevante?*
- (c) *Que comparação adicional poderia agregar valor à investigação exploratória?*
- (d) *Existem features potencialmente importantes para estabelecer comparações?*

Nesse processo, é importante afastar-se do computador de tempos em tempos para refletir sobre suas descobertas. Você pode querer ler mais sobre o assunto ou consultar um especialista na área do domínio de aplicação do problema para discutir o que encontrou. Por exemplo, pode haver boas razões para uma observação incomum, e alguém da área pode ajudar a esclarecer a situação e fornecer mais contexto.



3 Sumarização Estatística

Seja uma amostra $X = \{x_1, x_2, x_3, \dots, x_n\}$ de n observações.

3.1 Medidas de Tendência Central

1. Média aritmética amostral:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

2. Média geométrica amostral:

$$\hat{x} = \left(\prod_{i=1}^n x_i \right)^{1/n} \quad (2)$$

3. Média harmônica amostral:

$$\ddot{x} = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \dots + \frac{1}{x_n}} \quad (3)$$

4. Mediana amostral:

$$\tilde{x} = \begin{cases} x_{(n-1)/2} & \text{se } n \text{ é ímpar.} \\ (x_{n/2} + x_{(n+1)/2})/2 & \text{caso contrário.} \end{cases} \quad (4)$$

aqui, x_i é a i -ésima observação de um conjunto ordenado.

5. Moda amostral é igual a observação com a frequência mais alta pra dados categóricos.

3.2 Medidas de Dispersão

1. Variância amostral:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (5)$$

2. Desvio padrão amostral:

$$s = \sqrt{s^2} \quad (6)$$

3. Coeficiente de variação:

$$cv = \frac{s}{\bar{x}} \quad (7)$$

4. Intervalo:

$$\text{range} = x_{\max} - x_{\min} \quad (8)$$

5. Percentis: o $100p$ -percentil é dado por

$$x_p = x_{\lfloor (n-1)p+1 \rfloor} \quad (9)$$

6. Intervalo semi-interquartil:

$$\text{SIQR} = \frac{Q_3 - Q_1}{2} \quad (10)$$

3.3 Medidas de Associação

1. Coeficiente de correlação de Pearson:

$$\rho_p = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (11)$$

2. Coeficiente de correlação de *rank* de Spearman:

$$\rho_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (12)$$

em que d_i é a diferença entre os *rank*s das variáveis correspondentes.

3.4 Medidas de Forma

1. Coeficiente de assimetria ou *skewness*:

$$\gamma_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n \times s^3} \quad (13)$$

2. Coeficiente de curtose:

$$\kappa = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - 3 \quad (14)$$

3.5 Selecionando Medidas de Localização




Figura 1: Fluxograma para selecionar uma medida de localização.

A Figura 1 apresenta o fluxograma para selecionar uma medida de localização de acordo com as características da distribuição de uma amostra de um conjunto de dados.

3.6 Selecionando Medidas de Dispersão

A Figura 2 apresenta o fluxograma para selecionar uma medida de dispersão de acordo com as características da distribuição de uma amostra de um conjunto de dados.

3.7 Selecionando Medidas de Associação

Caso um par de variáveis apresente um relacionamento linear, então deve-se utilizar o Coeficiente de correlação de Pearson. Caso contrário, se o par de variáveis apresenta um relacionamento não linear, então deve-se utilizar o Coeficiente de correlação de *rank* de Spearman.




Figura 2: Fluxograma para selecionar uma medida de dispersão.

4 Juntando Estatística Descritiva & Visualização de Dados

As seções a seguir unem técnicas de estatística descritiva e visualização de dados para realização da análise exploratória de dados.

4.1 Identificando o Tipo de Relacionamento entre Variáveis

Sejam X e Y um par de variáveis ou *features* para as quais se pretende identificar a linearidade ou não linearidade, e a e b duas constantes. A Tabela 2 apresenta como realizar o teste de linearidade.

Tabela 2: Tipo de relacionamento entre variáveis.

Eixo-X	Eixo-Y	Tipo de Relacionamento	Nome
Sem escala logarítmica	Sem escala logarítmica	$Y = aX + b$	Linear
Com escala logarítmica	Sem escala logarítmica	$Y = a \log X + b$	Log-Linear
Sem escala logarítmica	Com escala logarítmica	$Y = ba^X$	Linear-Log
Com escala logarítmica	Com escala logarítmica	$Y = bX^a$	Log-Log

Para verificar os tipos de relacionamentos da Tabela 2, também é importante utilizar um gráfico de dispersão para confirmar as relações.

NOTA IMPORTANTE: a identificação do tipo de relacionamento entre variáveis pode ajudar a selecionar um modelo de aprendizado de máquina para iniciar os experimentos do projeto de Ciência de Dados. Relacionamentos não lineares exigem modelos mais complexos, esse conteúdo será explorado em outra disciplina referente à Aprendizado de Máquina Supervisionado.

4.2 Como Identificar e Tratar *Outliers*

1. Identifique os *outliers* por meio do uso do:

- (a) coeficiente de curtose: $\kappa > 0$ é uma indicação de *outliers*;
- (b) gráfico de Boxplot;
- (c) gráfico de dispersão;

2. Decida se você deve ou não incluir os *outliers*:




Figura 3: Exemplos distribuições e seu relacionamento com as medidas de localização.

- (a) Verifique se os *outliers* são parte do contexto do problema ou se são exceções que devem ser retiradas;
- (b) Analise os dados **COM outliers** e **SEM outliers** e veja o que faz mais sentido;
- (c) Todas as análises dependem da natureza e do contexto do problema em estudo.

4.3 Como Identificar e Tratar a Forma da Distribuição

A Figura 3 ilustra o relacionamento entre os diferentes tipos de distribuições utilizando um gráfico de densidade ou gráfico de histograma com relação às medidas de localização, tais como média, mediana e moda.

Ainda, a partir da Figura 3, também é possível estabelecer um relacionamento de cada tipo de distribuição com a medida de forma do coeficiente de assimetria ou *skewness*:

- (a) $\gamma_1 = 0$: distribuição simétrica ou em formato de sino na Figura 3(a).
- (b) $\gamma_1 > 0$: distribuição *right-skewed* na Figura 3(b).
- (c) $\gamma_1 < 0$: distribuição *left-skewed* na Figura 3(c).

NOTA IMPORTANTE: distribuições multimodais como a da Figura 3(d) podem apresentar coeficientes de assimetria com $\gamma_1 = 0$, $\gamma_1 < 0$ ou $\gamma_1 > 0$, apesar disso, continuam sendo multimodais. Então, é importante construir um gráfico de densidade ou histograma para verificar sua forma.

O coeficiente de curtose mostra o grau de achatamento de uma distribuição, ou seja, mostra o quanto os dados estão espalhados ou dispersos em torno da média conforme mostra a Figura 4:

- (a) $\kappa = 0$: Mesocúrtica, semelhante a uma distribuição Normal, ou seja, em formato de sino;
- (b) $\kappa < 0$: Platicúrtica, distribuição mais achatada;
- (c) $\kappa > 0$: Leptocúrtica, distribuição com um pico muito elevado.

NOTA IMPORTANTE: distribuições multimodais como a da Figura 3(d) podem apresentar coeficientes de curtose negativos, $\kappa < 0$ se tiverem um pico ou picos elevados, apesar disso, continuam sendo multimodais. Então, é importante construir um gráfico de densidade ou histograma para verificar sua forma.

A Tabela 3 mostra o tipo de transformação necessário para lidar com cada tipo de tendência ou inclinação em uma distribuição de dados.

NOTA IMPORTANTE: alguns modelos de Aprendizado de Máquina, a hipótese de normalidade pressupõe que seus dados ou os erros do modelo seguem uma distribuição gaussiana




Figura 4: Tipos de distribuição de acordo com o espalhamento dos dados em torno da média.

Tabela 3: Tipo de transformação de acordo com a forma da distribuição.

Tipo	Transformação	Observação
<i>Right-skewed</i>	Potência	Box-Cox é um tipo de transformação de potência.
<i>Left-skewed</i>	Logarítmica	Geralmente, aplica-se o logaritmo na base 10.
Multimodal	Kernel de base radial, do inglês, Radial Basis Function (RBF)	O método avalia a proximidade de um ponto de entrada X em relação a um ponto central que serve como referência. A forma mais comum é a Função Gaussiana Radial.

(curva em forma de sino). Então, para distribuições de dados de variáveis que apresentem uma tendência ou sejam multimodais, devem ser transformadas com o objetivo deixá-las de acordo com uma distribuição aproximadamente normal.

4.4 Identificando e Tratando Variáveis com Correlação Forte

Para identificar variáveis que são fortemente correlacionadas, os coeficientes de associação ou correlação de Pearson e Spearman podem ser utilizados. Para facilitar essa identificação, um gráfico do tipo heatmap pode ser utilizado. Depois de construído, basta identificar os pares de variáveis que são fortemente correlacionadas utilizando a seguinte “*role of the thumb*”:

- (a) variáveis com correlação forte: $\rho > 0.75$ e $\rho < -0.75$;
- (b) variáveis com correlação moderada: $\rho \in [0.50, 0.75]$ e $\rho \in [-0.75, -0.50]$;
- (c) variáveis com correlação fraca: $\rho \in (-0.50, 0.50)$.

NOTA IMPORTANTE: variáveis dependentes altamente correlacionadas devem ser tratadas para evitar o problema de **multicolinearidade** que pode afetar modelos de Aprendizado de Máquina Supervisionado e Não-Supervisionado. Dentre o par de variáveis dependentes altamente correlacionado, deve-se escolher uma variável para remover, geralmente, remove-se aquela que é menos interpretável para o problema ou utiliza-se um método quantitativo para remoção, tal como, por exemplo, análise de *loadings* da Análise de Componente Principal, do inglês, Principal Component Analysis (PCA). Essa análise de *loadings* permite identificar qual variável carrega mais ou menos informação para o modelo em termos de variação explicada.

ATENÇÃO: em um problema de regressão em Aprendizado Supervisionado, por exemplo, uma correlação forte entre uma variável dependente e uma variável independente é bom para o modelo, pois ajuda a prever os valores alvo. Portanto, desse tipo de par entre a variável dependente e a variável(eis) independente(s) **NÃO** se deve remover uma variável.