

# **Estatística Descritiva e Visualização de Dados**

Professor: Alexandre Magno de Sousa

**Curso de Especialização em Ciência de Dados**

Departamento de Computação e Sistemas - DECSI

Instituto de Ciências Exatas e Aplicadas - ICEA

Universidade Federal de Ouro Preto - UFOP

# Sumário

## Explorando distribuições

Histograma.

Gráfico de densidade e estimativas.

Gráfico da função de distribuição acumulada.

Gráfico de caixas.

Gráfico de dispersão.

Gráfico de mapa de calor.

Juntando tudo:

*Sumarização estatística e visualização de dados.*


*"It is not what you say, but how you say it."*  
— A. Putt

*"Statistics is the art of lying by means of figures."*  
— Dr. Wilhelm Stekhel

# Cronograma

| Conteúdo                                                                                                            | Data       |
|---------------------------------------------------------------------------------------------------------------------|------------|
| Sumarização Estatística: tipos de dados, medidas de localização, dispersão, forma e de associação.                  | 01/07/2026 |
| Visualização de distribuições: tipos de gráficos e elementos visuais, conectando visualização com sumarização.      | 04/07/2026 |
| Sumarização e visualização de categóricos & variáveis múltiplas: dados binários e categóricos, múltiplas variáveis. | 08/07/2026 |
| Princípios e narrativas da Análise Exploratória de Dados: diretrizes para EDA e como contar histórias com dados.    | 11/07/2026 |

Boa parte do tempo....



# O que é Visualização dos dados?

**Visualização de dados** é o processo de transformar dados brutos e complexos em **elementos visuais/formatos visuais**, como gráficos, mapas e painéis interativos.

# Limitações da Estatística Descritiva

Dados podem ser descritos por meio de várias medidas de estatísticas descritivas:

*média, mediana, somas, correlações, etc...*

Porém, agregar dados sempre **perde informação!**

Às vezes, uma análise visual faz muito mais sentido.


# Limitações da Estatística Descritiva

Motivados pelo Anscombe's Quartet, em 2017 pesquisadores criaram uma técnica para gerar dados sintéticos de formas diversas que compartilham a mesma informação agregada.

## **Same Stats, Different Graphs: Generating Datasets with Varied Appearance and Identical Statistics through Simulated Annealing**

**Justin Matejka and George Fitzmaurice**  
Autodesk Research, Toronto Ontario Canada  
*{first.last}@autodesk.com*





X Mean: 54.2659224

Y Mean: 47.8313999

X SD : 16.7649829

Y SD : 26.9342120


Corr. : -0.0642526

# Explorando Distribuições

Note que a terceira linha, o Boxplot, é o mesmo para dados bem diferentes.

Boxplots capturam **APENAS** estatísticas agregadas dos dados:

*Mediana e quartis.*




# Histogramas

Um histograma mostra a **frequência relativa** de vários valores de um parâmetro.

O histograma conta o número de linhas dentro de uma faixa.


Para isso, é necessário definir o **número de bins** (ou caixas).

Ou seja, **agrupar** dados no **eixo-x**.




# Histogramas

Exemplo: **distribuição** de lucro médio dos filmes.



# Histogramas

Quais insights temos deste gráfico?



# Histogramas

A escolha do **número de bins** afeta o gráfico.

Parece que tem uma tendência decrescente no mesmo.


Será que é verdade? *Podemos plotar de outras formas...*

# Histograma

Sempre existe um problema que é a escolha do número de bins.


Uma solução é filtrar o outlier, ou seja, remover este ponto.

Também vamos normalizar.



# Histograma

Mudar o número de bins também ajuda, aqui o o bin é 50.





# Como escolher o número de bins?

Escolher o número de bins é uma arte.

Este é um problema de histogramas.

## **Alternativas:**

1. Gráficos de distribuições cumulativas (CDF e CCDFs)
2. Sumarização de dados em boxplots/violinplots/beanplots . . .


# Gráficos de densidades e estimativas

Relacionado ao histograma, mostra a **distribuição dos valores** como uma **linha contínua**.

Pode ser imaginado como um **histograma suavizado**, apesar de ser computado por meio de uma função **kernel density estimate (KDE)**.

A principal diferença com relação ao histograma é a escala do eixo-y:

- *no histograma é a **contagem** da frequência dos dados entre dois pontos.*
- *no gráfico de densidade é uma **proporção** da distribuição entre dois pontos.*



# Gráficos de densidades e estimativas

## Quando utilizar?

- *Funciona melhor para mostrar a distribuição de valores contínuos.*
- *Comparar múltiplas distribuições.*
- *Mostra como os valores estão espalhados e destaca inclinações, picos ou vales.*
- *Ajuda a identificar agrupamentos, múltiplas modas e mudanças sutis na distribuição que não podem ser observados no histograma.*

**Resumindo:** deve ser utilizado quando você precisa compreender a **forma** e a **distribuição** dos dados em detalhes!

# Gráficos de densidades e estimativas

## Quando NÃO utilizar?

- *Para conjuntos de dados pequenos demais: pode gerar um gráfico enganoso.*
- *Para dados discretos ou categóricos: pode gerar gráficos sem sentido.*

# Gráfico da função de distribuição acumulada empírica

Com dados contínuos, às vezes é melhor construir uma função de distribuição acumulada, do inglês, **Cumulative Distribution Function (CDF)**.


- descreve as *probabilidades* de uma variável aleatória assumir *valores menores ou iguais a x*.
- é uma *função cumulativa* porque soma a probabilidade total até aquele ponto.

**Definição:**

$$\text{CDF}(x) = P(x \leq X).$$

*Como construir uma para o conjunto de dados?*

# Gráfico da função de distribuição acumulada empírica





CDF é calculada como a área da curva no 1º gráfico a partir de  $x = 0$  até  $x = 5$ :

$$P(X \leq 5) = F(5) = \int_{x=0}^5 \lambda e^{-\lambda x} dx = 1 - e^{-\lambda x}$$

# Gráfico da função de distribuição acumulada empírica

Relação entre Probability Density Function (PDF) e CDF:

- *A PDF mostra o formato da distribuição.*
- *A CDF mostra a soma acumulada das probabilidades.*



# Gráfico da função de distribuição acumulada empírica

Seja o conjunto  $X = \{12, 7, 15, 20, 15\}$ , para o cálculo da ECDF:

1. Determine o número de observações:  $n = 5$ .
2. Ordene os dados:  $\{7, 12, 15, 15, 20\}$ .
3. Calcule a ECDF de cada valor que é a quantidade de elementos menores ou iguais aquele valor:
  - a. Para  $x = 7$ , existe 1 número  $\leq 7$ :  $1/5 = 0.2$ , então  $P(x \leq 7) = 20\%$ .
  - b. Para  $x = 12$ , existem 2 números  $\leq 12$ :  $2/5 = 0.4$ , então  $P(x \leq 12) = 40\%$ .
  - c. Para  $x = 15$ , existem 4 números  $\leq 15$ :  $4/5 = 0.8$ , então  $P(x \leq 15) = 80\%$ .
  - d. Para  $x = 20$ , existem 5 números  $\leq 20$ :  $5/5 = 1.0$ , então  $P(x \leq 20) = 100\%$ .



# Gráfico da função de distribuição acumulada empírica

Use o módulo **statsmodels** que possui uma classe **ECDF** que calcula a probabilidade acumulada para cada elemento.

[https://www.statsmodels.org/devel/generated/statsmodels.distributions.empirical\\_distribution.ECDF.html](https://www.statsmodels.org/devel/generated/statsmodels.distributions.empirical_distribution.ECDF.html)


# Gráfico da função de distribuição acumulada empírica

Use um gráfico de **CDF empírica** para avaliar as seguintes características do seu conjunto de dados:


- 1. Percentis e proporções para intervalos de dados.*
- 2. Identificação de onde ocorre a maioria dos valores.*
- 3. Avaliação da amplitude dos dados.*
- 4. Comparação de distribuições amostrais.*
- 5. Determinação de quão bem os dados seguem uma distribuição ajustada.*

# Gráfico de caixas ou Boxplot

É uma boa forma de sumarizar os quartis dos dados.



# Gráfico de caixas ou Boxplot




# Gráfico de caixas ou boxplot

Abordagem simples: encontrar 5 números que sumarizam as observações.

1. Identificar a **mediana**.
2. Identificar o **maior** e o menor **valor**.
3. Identificar a **mediana entre o menor e a mediana geral**.
4. Identificar a **mediana entre o maior e a mediana geral**.
5. Calcule o tamanho do **IQR e multiplique por 1.5**, esse valor será o bound.
6. Um **outlier** será um número cuja a diferença com Q1 é menor do que bound ou cuja a diferença com Q3 é maior do bound.
7. Ordene os números do menor para o maior.

# Gráfico de caixas ou boxplot




$$\text{Bound} = IQR \times 1.5$$
$$\text{Bound} = 8 \times 1.5 = 12$$

# Gráfico de caixas ou Boxplot


O Box plot ilustra características de estatísticas básicas:

- **Curto/Estreito:** indica que a maioria das observações são similares.
- **Grande:** indica que a maioria das observações são diferentes.
- **Mediana:** se **NÃO** está na linha do meio, isso é uma indicação de que os dados são skewed (i.e. enviesados ou tendenciosos), **caso contrário**, se a mediana está próxima da parte:
  - *Inferior* , indica que a maioria dos dados apresentam valores menores.
  - *Superior* , indica que maioria dos dados apresentam valores grandes;
- **Whiskers:**
  - *Longos* : as observações apresentam valores de desvio padrão e variância altos.
  - Se é maior de um lado do que outro, significa que os dados são *inclinados em uma direção* .

# Gráfico de caixas ou Boxplot



(a) Vertical Boxplot




(b) Horizontal Boxplot



# Gráfico de caixas ou Boxplot: variações


## Boxplot de largura

**variável:** a largura da caixa é ajustada para representar o tamanho dos dados em cada grupo.




## Boxplot com entalhes ou Notched Boxplot:

estrita-se no valor da mediana para representar um intervalo de confiança em torno da mediana,



## Gráfico de violino:

combina um boxplot com um gráfico de densidade de uma distribuição.




# Gráfico de dispersão ou Scatter plot

A forma padrão para visualizar o relacionamento entre duas variáveis/features é utilizar o gráfico de dispersão.

- o **eixo-x** representa uma variável.
- o **eixo-y** representa a outra variável.
- e **cada ponto** no gráfico é um registro ou instância.


# Gráfico de dispersão ou Scatter plot

---




# **Erros comuns na preparação de gráficos**


# Queremos evitar gráficos ruins!




**Countries by Proportion of World Population**



# Queremos evitar gráficos ruins!




# Queremos evitar gráficos ruins!




# Problemas de Escala

Qual o problema com o gráfico abaixo?






# Problemas de Escala



# Problemas de Escala

E com este gráfico aqui? (Figura do data8.org)



From [Gizmodo](#), this shows battery size in the new iPad versus that of the iPad 2. The battery in the former is 70 percent bigger than that of the latter. Something's not right here.


From Flowing Data: <http://flowingdata.com/2012/03/16/new-ipad-battery-size-is-huge/>

# Problemas de Escala


Tentem focar no aspecto visual




Se isto é o total.






Aqui está o dobro.




Não um aumento na área







# Problemas de Escala: incluindo o Zero!



Incluir o Zero não ajuda a visualizar o relacionamento linear entre as variáveis!


# Problemas de Escala: incluindo o Zero!

Sem o eixo iniciar em Zero, pode dar a impressão de que small têm 2x a longevidade de large!






**Incluir o Zero** nos ajuda a ter a percepção correta do que realmente ocorre nos dados!

## Revelando a forma por meio da mudança de escala nos eixos



Configurando o eixo x em **escala logarítmica**, a distribuição dos dados parece ser mais simétrica.




# Revelando a forma por meio da mudança de escala nos eixos



Configurando os eixos x e y em **escala logarítmica**, o relacionamento entre as variáveis é revelado!



# Revelando o tipo de relacionamento entre variáveis



Não tem relacionamento linear.

- Com a mudança de escala, percebe-se um relacionamento aproximadamente linear.
- Então, podemos dizer que existe um **relacionamento log-linear** entre as variáveis Weight e Height.

# Revelando o tipo de relacionamento entre variáveis

Sejam **x** e **y** duas **variáveis/features** para as quais pretende-se identificar a linearidade ou não linearidade:

| EIXO-X                    | EIXO-Y                    | RELACIONAMENTO          | NOME       |
|---------------------------|---------------------------|-------------------------|------------|
| Sem escala<br>logarítmica | Sem escala<br>logarítmica | Linear: $y = ax + b$    | Linear     |
| Escala<br>Logarítmica     | Sem escala<br>logarítmica | Log: $y = a \log x + b$ | Log-Linear |
| Sem escala<br>logarítmica | Escala<br>Logarítmica     | Exponencial: $y = ba^x$ | Linear-Log |
| Escala<br>Logarítmica     | Escala<br>Logarítmica     | Potência: $y = bx^a$    | Log-Log    |

# Um guia para gráficos

<https://www.storytellingwithdata.com/chart-guide>

storytelling WITH data

TRAININGS ▾ RESOURCES ▾ COMMUNITIES ▾ ABOUT ▾ SEARCH

BOOK A WORKSHOP




choose an  
effective visual

*With the*

**SWD CHART GUIDE**

The *storytelling with data* guide to charts and graphs


AREA CHART



BAR CHART



BOXPLOT




BUBBLE CHART



# **Juntando tudo:** **Sumarização Estatística e Visualização de Dados**

Jupyter Notebook Python

# Análise do Panorama Geral do Problema



## California Housing Prices dataset:

- Baseado nos dados do censo de 1990.
- Apresenta métricas como: população, renda média, preço do imóvel.
- Grupos de blocos ou distritos são a menor unidade geográfica (população entre 600 e 3000 habitantes)

# Análise do Panorama Geral do Problema


- A solução deverá aprender com os dados e ser capaz de prever o preço médio do imóvel em qualquer distrito dado o conjunto das outras métricas (features).

- Como a empresa espera utilizar e se beneficiar da solução?

*conhecer o objetivo é importante pois ajudará a tratar o problema!*

- Como é a solução atual?

*a situação atual fornece uma referência para o desempenho e também provê insights importantes de como resolver o problema.*



# Análise do Panorama Geral do Problema

Features do conjunto de dados:

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 20640 entries, 0 to 20639  
Data columns (total 10 columns):  
#   Column                Non-Null Count  Dtype  
---  -  
0   longitude             20640 non-null  float64  
1   latitude              20640 non-null  float64  
2   housing_median_age    20640 non-null  float64  
3   total_rooms            20640 non-null  float64  
4   total_bedrooms        20433 non-null  float64  
5   population            20640 non-null  float64  
6   households            20640 non-null  float64  
7   median_income         20640 non-null  float64  
8   median_house_value    20640 non-null  float64  
9   ocean_proximity       20640 non-null  object  
dtypes: float64(9), object(1)  
memory usage: 1.6+ MB
```

Dezenas de  
milhares de  
dólares!



# Sumarização Estatística




|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |

## Para cada feature:

1. Os valores das features estão todos na **mesma unidade**? Se sim, **com outliers** ou **sem outliers**? (talvez Mediana?)
2. Existem **escalas diferentes** ou os dados foram **normalizados**? (talvez Média Geométrica!)
3. Estamos trabalhando com **taxas**? (talvez Média Harmônica!)




## Tendências centrais: quando utilizar cada uma?




# Tendências centrais e distribuição de dados


Relacionamento entre medidas de localização e distribuição de dados.




(a) Distribuição simétrica.



(b) Distribuição *right-skewed*.



(c) Distribuição *left-skewed*.



(d) Distribuição multimodal.

# Sumarização Estatística

Indica outliers!




|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |


## Para cada feature:

1. Os valores das features estão todos na **mesma unidade**? Se sim, **com outliers** ou **sem outliers**? (talvez Mediana?)
2. Existem **escalas diferentes** ou os dados foram **normalizados**? (talvez Média Geométrica!)
3. Estamos trabalhando com **taxas**? (talvez Média Harmônica!)

# Sumarização Estatística



# Sumarização Estatística



# Sumarização Estatística

|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |


Indica  
distribuição  
inclinada!

Indica  
outliers!

## Para cada feature:

1. Os valores das features estão todos na **mesma unidade**? Se sim, **com outliers** ou **sem outliers**? (talvez Mediana?)
2. Existem **escalas diferentes** ou os dados foram **normalizados**? (talvez Média Geométrica!)
3. Estamos trabalhando com **taxas**? (talvez Média Harmônica!)

# Medidas de dispersão: qual utilizar?



**Nota:** exemplos de distribuição limitada são idade, percentuais, pontuação de teste. Valores infinitos não são possíveis!



# Sumarização Estatística

Indica distribuição  
simétrica e  
unimodal!



|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |

## Para cada feature:

1. Os valores das features estão todos na **mesma unidade**? Se sim, **com outliers** ou **sem outliers**? (talvez Mediana?)
2. Existem **escalas diferentes** ou os dados foram **normalizados**? (talvez Média Geométrica!)
3. Estamos trabalhando com **taxas**? (talvez Média Harmônica!)




# Sumarização Estatística

Valores de skewness próximos de 0!

Indica distribuição simétrica e unimodal!

Mas, cuidado!!!  
Será que é unimodal?









|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |

## Observação:


1. Pelos valores de assimetria, o **coeficiente de variação** NÃO ajudará muito na análise de dispersão!

# Sumarização Estatística

Distribuições multimodais!






# Sumarização Estatística: Transformações de dados



*Gaussian RBF feature* medindo a similaridade entre "house median age" e o ponto fixo de 35.

# Sumarização Estatística



# Sumarização Estatística



|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |

## Observação:

1. Pelos valores de assimetria, o **coeficiente de variação** NÃO ajudará muito na análise de dispersão!
2. Então, devemos analisar a dispersão observando **SIQR** ou **percentil**!

# Sumarização Estatística

Única distribuição limitada!

|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |

## Observação:

1. Pelos valores de assimetria, o **coeficiente de variação** NÃO ajudará muito na análise de dispersão!
2. Então, devemos analisar a dispersão observando **SIQR ou percentil**!



# Sumarização Estatística



|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |

## Observação:

1. Pelos valores de assimetria, o **coeficiente de variação** NÃO ajudará muito na análise de dispersão!
2. Então, devemos analisar a dispersão observando **SIQR ou percentil**!

# Sumarização Estatística



|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |


## Observação:

1. Pelos valores de assimetria, o **coeficiente de variação** NÃO ajudará muito na análise de dispersão!
2. Então, devemos analisar a dispersão observando **SIQR ou percentil**!




# Medidas de forma

**Assimetria** ou *skewness* é a falta de simetria observada quando os dados são concentrados em um dos lados da distribuição.




(a) Distribuição simétrica.

$$\text{Skewness} = 0$$



(b) Distribuição assimétrica à direita (*right-skewed*).

$$\text{Skewness} < 0$$




(c) Distribuição assimétrica à esquerda (*left-skewed*).

$$\text{Skewness} > 0$$

# Medidas de forma

**Curtose:** apresenta o grau de achatamento de uma distribuição, ou seja, o quanto os dados estão espalhados em torno da média.

- Distribuições com **curtose alta** (*leptocúrticas*) têm um pico mais agudo e caudas mais pesadas, ou seja, presença de **outliers**!
- Distribuições com **curtose baixa** (*platicúrticas*) são mais achatadas.



$$\kappa = \frac{1}{n} \sum_{i=1}^n \left( \frac{x_i - \bar{x}}{s} \right)^4 - 3$$

- Platicúrticas: **kurtosis** < 0.
- Leptocúrticas: **kurtosis** > 0.
- Mesocúrticas: **kurtosis** = 0.

# Sumarização Estatística




|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |

**Observação:** *total\_rooms, total\_bedrooms, population, households, median\_income e median\_house\_value.*


1. **Assimetria > 0:** right skewed ou inclinação para à direita.
2. **Curtose > 0:** pico alto e outliers.

# Sumarização Estatística




# Sumarização Estatística

Merece atenção!









# Sumarização Estatística: Transformações de dados

Exemplo de distribuição de causa pesada:



# Sumarização Estatística



# Sumarização Estatística: Transformações de dados

Tipos de transformações e quando aplicá-las:




1. Distribuições *right-skewed*: transformação **logarítmica**.
2. Distribuições *left-skewed*: transformação **Box-Cox**.
3. Distribuições *multimodais*: *radial basis function* (RBF) ou alguma função que dependa somente da distância entre um valor de entrada e um ponto fixo.

*esta última não está relacionada à cauda pesada!*






# Sumarização Estatística

Aplicação de filtros para remoção de outliers!









```
df[df['median_house_value'] < 500000].plot.scatter(x='median_house_value',y='housing_median_age')
```






# Sumarização Estatística

Aplicação de filtros para remoção de outliers!






# Sumarização Estatística

Aplicação de filtros para remoção de outliers!









```
df[(df['median_house_value'] < 500000) &  
    (df['housing_median_age'] < 52)].plot.scatter(x='median_house_value', y='housing_median_age')
```





# Sumarização Estatística

Aplicação de filtros para remoção de outliers!



# Sumarização Estatística

Indica distribuição inclinada!


Indica outliers!

|                    | count   | mean      | std       | cv    | min      | 25%       | 50%       | 75%       | max       | skewness | kurtosis |
|--------------------|---------|-----------|-----------|-------|----------|-----------|-----------|-----------|-----------|----------|----------|
| longitude          | 20640.0 | -119.57   | 2.00      | -0.02 | -124.35  | -121.80   | -118.49   | -118.01   | -114.31   | -0.30    | -1.33    |
| latitude           | 20640.0 | 35.63     | 2.14      | 0.06  | 32.54    | 33.93     | 34.26     | 37.71     | 41.95     | 0.47     | -1.12    |
| housing_median_age | 20640.0 | 28.64     | 12.59     | 0.44  | 1.00     | 18.00     | 29.00     | 37.00     | 52.00     | 0.06     | -0.80    |
| total_rooms        | 20640.0 | 2635.76   | 2181.62   | 0.83  | 2.00     | 1447.75   | 2127.00   | 3148.00   | 39320.00  | 4.15     | 32.63    |
| total_bedrooms     | 20433.0 | 537.87    | 421.39    | 0.78  | 1.00     | 296.00    | 435.00    | 647.00    | 6445.00   | 3.46     | 21.99    |
| population         | 20640.0 | 1425.48   | 1132.46   | 0.79  | 3.00     | 787.00    | 1166.00   | 1725.00   | 35682.00  | 4.94     | 73.55    |
| households         | 20640.0 | 499.54    | 382.33    | 0.77  | 1.00     | 280.00    | 409.00    | 605.00    | 6082.00   | 3.41     | 22.06    |
| median_income      | 20640.0 | 3.87      | 1.90      | 0.49  | 0.50     | 2.56      | 3.53      | 4.74      | 15.00     | 1.65     | 4.95     |
| median_house_value | 20640.0 | 206855.82 | 115395.62 | 0.56  | 14999.00 | 119600.00 | 179700.00 | 264725.00 | 500001.00 | 0.98     | 0.33     |


**Observação:** *total\_rooms, total\_bedrooms, population, households, median\_income e median\_house\_value.*

1. **Assimetria > 0:** right skewed ou inclinação para à direita.
2. **Curtose > 0:** pico alto e outliers.


# Sumarização Estatística



# Sumarização Estatística




Pearson




Spearman

# Sumarização Estatística




Pearson



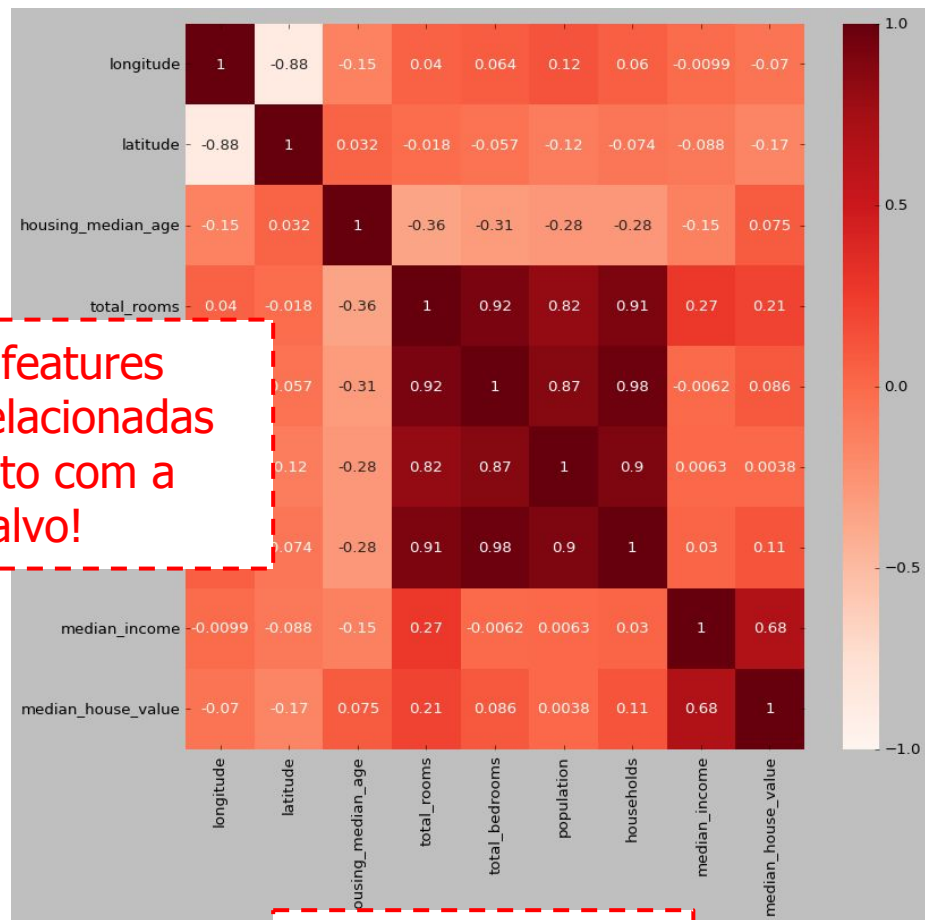
Spearman



# Sumarização Estatística



Pearson



Spearman

# Sumarização Estatística

- Existe a necessidade da remoção de **outliers**.
- Existe a necessidade de aplicar **transformação nos dados**, mas, depende do objetivo da solução do problema!
  - *para um problema de regressão linear, a variável alvo não deve ser transformada.*
- Aplicação de **transformação logarítmica** para função de distribuições **right-skewed**.
- Aplicação de **transformação de kernel de base radial**, do inglês Radial Basis Function, (RBF) Gaussiana em função de distribuições **multimodais**.
- Remoção de features altamente correlacionadas (exceto a variável alvo) para evitar **problema de multicolinearidade**.
- Os gráficos ainda podem ser configurados de forma customizada: <https://matplotlib.org/>
- Para **engenharia de features**:
  - *as **features de localização geográfica** podem ser utilizadas para criação de **novas features**.*
  - *as **features categóricas** devem ser codificadas (**One hot encoding/Ordinal encoding**).*

# Bibliografia

[Bruce, Bruce & Gedek] Bruce, Peter; Bruce, Andrew; Gedeck, Peter. **Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python**. 2nd ed. California, USA: O'Reilly Media, 2020.

[Downey, 2025] Downey, Allen B.. **Think Stats: Exploratory Data Analysis**. California, USA: O'Reilly Media, 2025.

[Géron, 2022] Géron, Aurélien. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**. O'Reilly, 2022.

[Lau, Gonzalez & Nolan, 2023] Lau, Sam; Gonzalez, Joseph; Nolan, Deborah. **Learning Data Science: Data Wrangling, Exploration, Visualization, and Modeling with Python**. California, USA: O'Reilly Media, 2023.

[VanderPlas, 2016] VanderPlas, Jake. **Python Data Science Handbook: Essential Tools for Working with Data**. California, USA: O'Reilly Media, 2016.