

Estatística Descritiva e Visualização de Dados

Professor: Alexandre Magno de Sousa

Curso de Especialização em Ciência de Dados

Departamento de Computação e Sistemas - DECSI

Instituto de Ciências Exatas e Aplicadas - ICEA

Universidade Federal de Ouro Preto - UFOP

Sumário

Explorando dados categóricos

Moda e valor esperado

Gráfico de barras

Gráfico de pizza

Explorando múltiplas variáveis

Duas variáveis categóricas

Dados categóricos e numéricos

Visualização de múltiplas variáveis

Compartimentação hexagonal e curvas de nível

Diretrizes para Análise Exploratória de Dados

Juntando tudo:

Visualização de dados categóricos e múltiplas variáveis


"If you can't convince them, confuse them."
— Truman's Law

"He uses statistics as a drunken man uses lamp-posts — for support rather than for illumination."
— Andrew Lang

Cronograma

Conteúdo	Data
Sumarização Estatística: tipos de dados, medidas de localização, dispersão, forma e de associação.	01/07/2026
Visualização de distribuições: tipos de gráficos e elementos visuais, conectando visualização com sumarização.	04/07/2026
Sumarização e visualização de categóricos & variáveis múltiplas: dados binários e categóricos, múltiplas variáveis.	08/07/2026
Princípios e narrativas da Análise Exploratória de Dados: diretrizes para EDA e como contar histórias com dados.	11/07/2026

Boa parte do tempo....



O que é Visualização dos dados?

Visualização de dados é o processo de transformar dados brutos e complexos em **elementos visuais/formatos visuais**, como gráficos, mapas e painéis interativos.

Explorando variáveis categóricas

Antes de fazer qualquer gráfico para explorar os dados, é importante é importante examinar os tipos das features.

Em alguns momentos nos referimos a uma feature como variável e a um tipo como tipo da variável.

Embora existam várias formas de categorizar os tipos das features, aqui vamos considerar apenas três tipos mais básicos:

Nominal

Ordinal

Quantitativo

Nominal

Uma variável que representa **categorias nomeadas**, nas quais não existe uma ordenação natural.

Exemplos: filiação partidária (Democrata, Republicano, Verde, Outro); o tipo de cão (pastoreio, sabujo, não esportivo, esportivo, terrier, toy, trabalho).

Ordinal

Medidas que representam **categorias ordenadas** são chamadas de ordinais. **Exemplos:** tamanho de camiseta (pequeno, médio, grande); nível de escolaridade (ensino médio, ensino superior, pós-graduação). Para uma variável ordinal, a diferença entre, digamos, "*pequeno*" e "*médio*" não precisa ser a mesma que a diferença entre "*médio*" e "*grande*".

NOTA: outro nome para dados categóricos é **Qualitativo**, ainda, **Dados Ordinais** e **Nominais** são subtipos de dados categóricos.

Quantitativo

Dados que representam **medidas numéricas** ou **quantidades** são chamados de quantitativos. **Exemplos:** a altura medida com precisão de um centímetro, o preço informado em dólares americanos (USD) e a distância medida com precisão de um quilômetro. As características quantitativas podem ser subdivididas em discretas e contínuas.

TERMOS CHAVE PARA DADOS CATEGÓRICOS

Moda

A categoria ou o valor que ocorre com **mais frequência** em um conjunto de dados.

Valor esperado

Quando as categorias podem ser associadas a um valor numérico, isso fornece um **valor médio** com base na **probabilidade de ocorrência** de uma categoria.

Gráficos de barras

A **frequência ou proporção** de cada categoria **representada por barras**.

Gráficos de pizza

A **frequência ou proporção** de cada categoria representada como **fatias de uma pizza**.

Explorando dados categóricos: moda

- A moda é o valor, ou valores, em caso de empate, que aparece com mais frequência nos dados.
- Por exemplo, no gráfico a moda da causa de atraso no aeroporto de Dallas/Fort Worth é "chegada" (*Inbound*).
- A moda é uma estatística resumida simples para dados categóricos e, geralmente, não é utilizada para dados numéricos.

exceto em algumas exceções!




Figure 1-5. Bar plot airline delays at DFW by cause

Explorando dados categóricos: valor esperado

Um tipo especial de dados categóricos consiste naqueles em que as categorias representam (ou podem ser mapeadas para) valores discretos em uma mesma escala.

Exemplo:

Um profissional de marketing de uma nova tecnologia em nuvem oferece dois níveis de serviço: um ao preço de US\$ 300/mês e outro a US\$ 50/mês.

Ele oferece webinars gratuitos para gerar leads (atrair o interesse do consumidor para transformá-los em potenciais compradores), e a empresa estima que 5% dos participantes contratarão o serviço de US\$ 300, 15% contratarão o serviço de US\$ 50 e 80% não contratarão nenhum dos dois.

Para fins financeiros, esses dados podem ser resumidos em um único "valor esperado", que é uma forma de média ponderada na qual os pesos são probabilidades.

Explorando dados categóricos: valor esperado

O **valor esperado** é calculado da seguinte forma:

- 1. Multiplique cada resultado pela sua probabilidade de ocorrência.*
- 2. Some esses valores.*

Nesse exemplo do serviço em nuvem, o valor esperado de um participante do webinar é de US\$ 22,50 por mês, calculado da seguinte maneira:

$$0.05 \times 300 + 0.15 \times 50 + 0.80 \times 0 = 22.5$$

O valor esperado é, na verdade, uma forma de **média ponderada**:

incorpora as noções de expectativas futuras e pesos de probabilidade, frequentemente baseados em julgamento subjetivo.

Explorando dados categóricos: gráfico de pizza

Um **gráfico de pizza** expressa uma relação de parte para o todo em seus dados.

Cada **fatia** representa um **componente**, e a soma de todas as fatias equivale ao todo.


Cada fatia de pizza possui três **componentes visuais**:

ângulo central, área e comprimento do arco.

Exemplo: imagine que você tenha um portfólio de cinco produtos e meça as vendas (em milhões de dólares) de cada um. A soma das vendas de cada produto individual equivale ao valor total de vendas.

Sales by product

TOTAL = \$75.2M






Explorando dados categóricos: gráfico de pizza

Existem dois **casos de uso principais** de quando utilizar para um **gráfico de pizza**:

1. *Se você deseja que seu público tenha uma noção geral da relação parte-todo em seus dados, comparar os tamanhos precisos das fatias é menos importante.*
2. *Para transmitir que um segmento do total é relativamente pequeno ou grande.*

Gráficos de pizza **NÃO devem ser utilizados** para avaliar o **tamanho relativo de categorias**, comparar dados entre **diferentes gráficos de pizza** ou visualizar **porcentagens cuja soma não totaliza 100%**.




Explorando dados categóricos: gráfico de pizza

Como fazer um bom gráfico de pizza?

Call breakdown by region
% OF TOTAL



Call breakdown by region
% OF TOTAL




Não construa várias fatias que sobrecarregam o gráfico.

Evite efeitos 3D e de explosão.


Too many slices

Declared majors
% OF ANDERSON HALL RESIDENTS




De-emphasize

Declared majors
% OF ANDERSON HALL RESIDENTS



Aggregate


Declared majors
% OF ANDERSON HALL RESIDENTS




Explorando dados categóricos: gráfico de pizza

Como fazer um bom gráfico de pizza?

Fruit purchases
% OF BASKETS



Fruit purchases
% OF BASKETS




Elimine a legenda e rotule os dados diretamente.


Classifique seus dados de forma significativa.

Survey responses
% OF TOTAL

■ Strongly agree
■ Agree
■ Neutral
■ Strongly disagree



Survey responses
% OF TOTAL




Explorando dados categóricos: gráfico de pizza


Como fazer um bom gráfico de pizza?

Use as cores estrategicamente.

Sales by product
TOTAL = \$75.2M



Sales by product
TOTAL = \$75.2M



- Vamos supor que queiramos destacar a contribuição do Produto A para o nosso portfólio de vendas.
- Qual dos seguintes gráficos de pizza chama mais efetivamente a sua atenção para o Produto A?

IDEIAS-CHAVE


- **Dados categóricos** são tipicamente **resumidos em proporções** e podem ser visualizados em um **gráfico de barras**.
- As **categorias** podem representar **itens distintos** (maçãs e laranjas, masculino e feminino), **níveis** de uma variável categórica (baixo, médio e alto) ou dados numéricos que foram agrupados em faixas.
- O **valor esperado** é a soma dos valores multiplicados por suas probabilidades de ocorrência, sendo frequentemente utilizado para **resumir os níveis** de uma variável categórica.

Explorando variáveis categóricas

Um conjunto de dados do [American Kennel Club \(AKC\)](#) sobre raças de cães registradas será utilizado para apresentar alguns conceitos relacionados à EDA.

- O AKC organiza eventos como o Campeonato Nacional, o Agility Invitational e o Obedience Classic, e cães sem raça definida são bem-vindos para participar da maioria dos eventos.
- O site [Information Is Beautiful](#) disponibiliza um conjunto de dados com informações da AKC sobre 172 raças:
- O conjunto de dados do AKC contém diversos tipos de atributos, e extraímos alguns deles que apresentam uma variedade de tipos de informação.
- Clique [aqui](#) para acessar esse conjunto de dados.

Explorando variáveis categóricas



Fonte: <https://informationisbeautiful.net/visualizations/best-in-show-whats-the-top-data-dog/>

Explorando dados categóricos

Dicionário de dados do conjunto de dados AKC:

Feature	Description
breed	Dog breed, e.g., Border Collie, Dalmatian, Vizsla
group	American Kennel Club grouping (herding, hound, non-sporting, sporting, terrier, toy, working)
score	AKC score
longevity	Typical lifetime (years)
ailments	Number of serious genetic ailments
purchase_price	Average purchase price from puppyfind.com
grooming	Grooming required once every: 1 = day, 2 = week, 3 = few weeks
children	Suitability for children: 1 = high, 2 = medium, 3 = low
size	Size: small, medium, large
weight	Typical weight (kg)
height	Typical height from the shoulder (cm)
repetition	Number of repetitions to understand a new command: <5, 5–15, 15–25, 25–40, 40–80, >80

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 172 entries, 0 to 171
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  -
0   breed           172 non-null    object
1   group           172 non-null    object
2   score           87 non-null     float64
3   longevity       135 non-null    float64
4   ailments        148 non-null    float64
5   purchase_price  146 non-null    float64
6   grooming        112 non-null    float64
7   children        112 non-null    float64
8   size            172 non-null    object
9   weight          86 non-null     float64
10  height          159 non-null    float64
11  repetition      132 non-null    object
dtypes: float64(8), object(4)
memory usage: 16.2+ KB
```

Explorando dados categóricos

Dicionário de dados do conjunto de dados AKC:

Feature	Description
breed	Dog breed, e.g., Border Collie, Dalmatian, Vizsla
group	American Kennel Club grouping (herding, hound, non-sporting, sporting, terrier, toy, working)
score	AKC score
longevity	Typical lifetime (years)
ailments	Number of serious genetic ailments
purchase_price	Average purchase price from puppyfind.com
grooming	Grooming required once every: 1 = day, 2 = week, 3 = few weeks
children	Suitability for children: 1 = high, 2 = medium, 3 = low
size	Size: small, medium, large
weight	Typical weight (kg)
height	Typical height from the shoulder (cm)
repetition	Number of repetitions to understand a new command: <5, 5–15, 15–25, 25–40, 40–80, >80

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 172 entries, 0 to 171
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   breed                 172 non-null   object
1   group                 172 non-null   object
2   score                 87 non-null    float64
3   longevity             135 non-null   float64
4   ailments              148 non-null   float64
5   purchase_price        146 non-null   float64
6   grooming              112 non-null   float64
7   children              112 non-null   float64
8   size                  172 non-null   object
9   weight                86 non-null    float64
10  height                159 non-null   float64
11  repetition            132 non-null   object
dtypes: float64(8), object(4)
memory usage: 16.2+ KB
```

Explorando dados categóricos

Dicionário de dados do conjunto de dados AKC:

Feature	Description
breed	Dog breed, e.g., Border Collie, Dalmatian, Vizsla
group	American Kennel Club grouping (herding, hound, non-sporting, sporting, terrier, toy, working)
score	AKC score
longevity	Typical lifetime (years)
ailments	Number of serious genetic ailments
purchase_price	Average purchase price from puppyfind.com
grooming	Grooming required once every: 1 = day, 2 = week, 3 = few weeks
children	Suitability for children: 1 = high, 2 = medium, 3 = low
size	Size: small, medium, large
weight	Typical weight (kg)
height	Typical height from the shoulder (cm)
repetition	Number of repetitions to understand a new command: <5, 5–15, 15–25, 25–40, 40–80, >80

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 172 entries, 0 to 171
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   breed                  172 non-null    object
1   group                  172 non-null    object
2   score                  87 non-null     float64
3   longevity              135 non-null    float64
4   ailments               148 non-null    float64
5   purchase_price         146 non-null    float64
6   grooming               112 non-null    float64
7   children               112 non-null    float64
8   size                   172 non-null    object
9   weight                 86 non-null     float64
10  height                 159 non-null    float64
11  repetition             132 non-null    object
dtypes: float64(8), object(4)
memory usage: 16.2+ KB
```

A chave primária é **breed**!

Explorando dados categóricos

Contagem agregada por categoria:

```
dogs['repetition'].value_counts()
```

```
repetition
25-40      39
15-25      29
40-80      22
5-15       21
80-100     11
<5         10
Name: count, dtype: int64
```

```
dogs['size'].value_counts()
```

```
size
medium     60
small      58
large      54
Name: count, dtype: int64
```

```
dogs['group'].value_counts()
```

```
group
terrier      28
sporting     28
working      27
hound        26
herding      25
toy          19
non-sporting 19
Name: count, dtype: int64
```

Dicionário de dados revisado

Feature	Description	Feature type	Storage type
breed	Dog breed, e.g., Border Collie, Dalmatian, Vizsla	primary key	string
group	AKC group (herding, hound, non-sporting, sporting, terrier, toy, working)	qualitative - nominal	string
score	AKC <code>score</code>	quantitative	floating point
longevity	Typical lifetime (years)	quantitative	floating point
ailments	Number of serious genetic ailments (0, 1, ..., 9)	quantitative - discrete	floating point
purchase_price	Average purchase price from puppyfind.com	quantitative	floating point
grooming	Groom once every: 1 = day, 2 = week, 3 = few weeks	qualitative - ordinal	floating point
children	Suitability for children: 1 = high, 2 = medium, 3 = low	qualitative - ordinal	floating point
size	Size: small, medium, large	qualitative - ordinal	string
weight	Typical weight (kg)	quantitative	floating point
height	Typical height from the shoulder (cm)	quantitative	floating point
repetition	Number of repetitions to understand a new command: <5, 5–15, 15–25, 25–40, 40–80, 80–100	Qualitative - ordinal	string

Dicionário de dados revisado

Feature	Description	Feature type	Storage type
breed	Dog breed, e.g., Border Collie, Dalmatian, Vizsla	primary key	string
group	AKC group (herding, hound, non-sporting, sporting, terrier, toy, working)	qualitative - nominal	string
score	AKC <code>score</code>	quantitative	floating point
longevity	Typical lifetime (years)	quantitative	floating point
ailments	Number of serious genetic ailments (0, 1, ..., 9)	quantitative - discrete	floating point
purchase_price	Average purchase price from puppyfind.com	quantitative	floating point
grooming	Groom once every: 1 = day, 2 = week, 3 = few weeks	qualitative - ordinal	floating point
children	Suitability for children: 1 = high, 2 = medium, 3 = low	qualitative - ordinal	floating point
size	Size: small, medium, large	qualitative - ordinal	string
weight	Typical weight (kg)	quantitative	floating point
height	Typical height from the shoulder (cm)	quantitative	floating point
repetition	Number of repetitions to understand a new command: <5, 5–15, 15–25, 25–40, 40–80, 80–100	Qualitative - ordinal	string

Explorando dados categóricos

Independente se uma variável é **nominal** ou **ordinal**, pode ser útil

renomear categorias para torná-las mais informativas.

agrupar categorias para simplificar uma visualização.

converter uma variável numérica em ordinal para focar em pontos de transição específicos.

Explorando dados categóricos: renomeando categorias

Estatísticas sumarizadas, como a média e a mediana, fazem sentido para dados quantitativos, mas geralmente não para dados qualitativos.

Faz sentido calcular o preço médio de raças (`breed`) de porte "Toy" (US\$ 687), mas não faz sentido calcular a adequação "média" da raça para `children`.

```
# Don't use this value in actual data analysis!  
dogs["children"].mean()
```

```
1.4910714285714286
```

NOTA

A principal diferença entre **tipos de armazenamento** e **tipos de feature** é que os tipos de armazenamento indicam quais **operações** podemos programar para realizar **cálculos**, enquanto os tipos de feature indicam quais **operações** fazem sentido para os **dados**.

Explorando dados categóricos: renomeando categorias

A variável `children` pode ser transformada substituindo os números por suas descrições em texto, convertendo 1, 2 e 3 em "alto", "médio" e "baixo".

Com *strings* as categorias estariam associadas ao seu significado e os rótulos dos gráficos teriam valores razoáveis por padrão.

Por exemplo, vamos focar apenas nas *raças de porte miniatura/companhia* ("toy" para variável `group`) e criar um gráfico de barras para variável `children`.

```
kids = {1:"high", 2:"medium", 3:"low"}  
dogs = dogs.assign(kids=dogs['children'].replace(kids))
```

```
dogs
```

	breed	group	score	longevity	...	weight	height	repetition	kids
0	Border Collie	herding	3.64	12.52	...	NaN	51.0	<5	low
1	Border Terrier	terrier	3.61	14.00	...	6.0	NaN	15-25	high
2	Brittany	sporting	3.54	12.92	...	16.0	48.0	5-15	medium
...	...	...	...	...	...	...	...	...	...
169	Wire Fox Terrier	terrier	NaN	13.17	...	8.0	38.0	25-40	NaN
170	Wirehaired Pointing Griffon	sporting	NaN	8.80	...	NaN	56.0	25-40	NaN
171	Xoloitzcuintli	non-sporting	NaN	NaN	...	NaN	42.0	NaN	NaN


172 rows × 13 columns

Explorando dados categóricos: renomeando categorias

Será criado um **gráfico de barras** das contagens de cada categoria de `children` que agora está em `kids` apenas para as raças de pequeno porte (`group = "toy"`):

→ `import plotly.express as px`

```
toy_dogs = dogs.query('group == "toy"').groupby('kids').count().reset_index()
px.bar(toy_dogs, x='kids', y='breed', width=350, height=250,
       category_orders={"kids": ["low", "medium", "high"]},
       labels={"kids": "Suitability for children", "breed": "count"})
```



Às vezes, uma variável qualitativa possui **muitas categorias** e é melhor ter uma visão dos dados em um nível mais alto, por isso, **as categorias devem ser agrupadas**.

Explorando dados categóricos: agrupando categorias

Será criada a variável `play` que irá agrupar categorias que compreendem as raças de companhia ("toy") e as não esportivas ("non-sporting").

As categorias restantes são colocadas em uma segunda categoria, que não entra na disputa.

```
with_play = dogs.assign(play=(dogs["group"] == "toy") |  
                           (dogs["group"] == "non-sporting"))
```

Agora a média faz sentido porque retorna a fração de valores `True`, quando valores booleanos são usados em cálculos numéricos, `True` torna-se 1 e `False` torna-se 0:

```
with_play['play'].mean()
```

```
0.22093023255813954
```

Explorando dados categóricos: quantitativo para ordinal

Outra mudança útil é a conversão de um valor numérico para categorias.

Por exemplo, podemos agrupar os valores da variável `ailments` em categorias: 0, 1, 2, 3, 4+. Em outras palavras, transformamos `ailments` de uma **variável quantitativa** em uma **variável ordinal**, utilizando o mapeamento 0 para "0", 1 para "1", 2 para "2", 3 para "3" e qualquer valor igual ou superior a 4 para "4+".

Uma boa prática **manter a feature original** pois:

*Quando uma variável quantitativa é convertida em ordinal, **informação é perdida**.*

O mesmo acontece quando categorias são agrupadas.

Explorando dados categóricos

Importância do tipo de feature para visualização de dados:

Feature type	Dimension	Plot
Quantitative	One feature	Rug plot, histogram, density curve, box plot, violin plot
Qualitative	One feature	Bar plot, dot plot, line plot, pie chart
Quantitative	Two features	Scatter plot, smooth curve, contour plot, heat map, quantile quantile plot
Qualitative	Two features	Side-by-side bar plots, mosaic plot, overlaid lines
Mixed	Two features	Overlaid density curves, side-by-side box plots, overlaid smooth curves, quantile quantile plot


O tipo de atributo também nos ajuda a decidir que tipo de estatística descritiva calcular.

Explorando dados categóricos: gráfico de barras

Um gráfico de barras pode ser utilizado para mostrar a distribuição de features categóricas.

```
import seaborn as sns
```

```
bins = [-0.5, 0.5, 1.5, 2.5, 3.5, 9.5]  
g = sns.histplot(data=dogs, x="ailments", bins=bins, stat="density")  
g.set(xlabel='Number of ailments', ylabel='density');
```



Apesar de quantitativa, a variável `ailment` é discreta, assim os intervalos dos bins foram ajustados.

As raças com quatro a nove `ailments` foram agrupadas em uma única categoria.

A mesma leitura do histograma com relação a tendência da distribuição pode ser feita para esse gráfico de barras, **porém...**

Explorando dados categóricos: gráfico de barras


GRÁFICO DE BARRAS ≠ HISTOGRAMA

Para dados qualitativos, o gráfico de barras desempenha um papel semelhante ao do histograma. O gráfico de barras oferece uma representação visual da “popularidade” ou frequência de diferentes grupos.

Conceitos como caudas e simetria não se aplicam a esse contexto, então, não pode ser interpretado como é feito no histograma ou gráfico de densidade.

```
kid_counts = dogs.groupby(['kids']).count()
kid_counts = kid_counts.reindex(["high", "medium", "low"])
```


> Click to show



Explorando múltiplas variáveis: qualitativo e quantitativo

Para examinar a relação entre uma **feature quantitativa** e uma **feature qualitativa**:


é possível utilizar a feature qualitativa para dividir os dados em grupos e comparar a distribuição da feature quantitativa entre esses grupos.



Explorando múltiplas variáveis: qualitativo e quantitativo

Boxplots lado a lado oferecem uma comparação parecida das distribuições entre grupos.
oferece uma compreensão básica de uma distribuição!

Gráficos de violino traçam curvas de densidade ao longo de um eixo para cada grupo. A curva é espelhada para criar um formato simétrico de "violino".
preenche a lacuna entre a curva de densidade e o boxplot!



Explorando múltiplas variáveis: qualitativo e qualitativo

Com **duas features qualitativas**, é possível comparar a distribuição de uma feature entre **subgrupos** definidos pela outra.

Uma feature é mantida como base e representa-se graficamente a distribuição da outra.

Por exemplo, é possível examinar a relação entre a adequação de uma raça para procriar (**children**) e o porte da raça (**size**).

```
def proportions(series):  
    return series / sum(series)  
  
counts = (dogs.groupby(['kids', 'size'])  
          .size()  
          .rename('count')  
          )
```

```
prop_table = (counts  
              .unstack(level=1)  
              .reindex(['high', 'medium', 'low'])  
              .apply(proportions, axis=1)  
              )
```


```
prop_table_t= prop_table.transpose()
```

```
prop_table_t
```

kids	high	medium	low
size			
large	0.37	0.29	0.1
medium	0.36	0.34	0.2
small	0.27	0.37	0.7

Tabela de
contingência!

```
fig = px.line(prop_table_t, y=prop_table_t.columns,  
              x=prop_table_t.index, line_dash='kids',  
              markers=True, width=500, height=250)  
  
fig.update_layout(  
    yaxis_title="proportion", xaxis_title="Size",  
    legend_title="Suitability <br>for children"  
)
```



Explorando múltiplas variáveis: qualitativo e qualitativo

Com **duas features qualitativas**, é possível comparar a distribuição de uma feature entre **subgrupos** definidos pela outra.


Uma feature é mantida como base e representa-se graficamente a distribuição da outra. Por exemplo, é possível examinar a relação entre a adequação de uma raça para procriar (**children**) e o porte da raça (**size**).

```
def proportions(series):  
    return series / sum(series)  
  
counts = (dogs.groupby(['kids', 'size'])  
          .size()  
          .rename('count')  
          )  
  
prop_table = (counts  
              .unstack(level=1)  
              .reindex(['high', 'medium', 'low'])  
              .apply(proportions, axis=1)  
              )  
  
prop_table_t= prop_table.transpose()
```

```
prop_table_t
```

kids	high	medium	low
size			
large	0.37	0.29	0.1
medium	0.36		
small	0.27		

```
fig = px.line(prop_table_t, y=prop_table_t.columns,  
              x=prop_table_t.index, line_dash='kids',  
              markers=True, width=500, height=250)  
  
fig.update_layout()
```



Explorando múltiplas variáveis: qualitativo e qualitativo


Com **duas features qualitativas**, é possível comparar a distribuição de uma feature entre **subgrupos** definidos pela outra.

Uma feature é mantida como base e representa-se graficamente a distribuição da outra.

Por exemplo, é possível examinar a relação entre a adequação de uma raça para procriar (`children`) e o porte da raça (`size`).

```
fig = px.bar(prop_table_t, y=prop_table_t.columns, x=prop_table_t.index,
             barmode='group', width=500, height=250)

fig.update_layout(
    yaxis_title="proportion", xaxis_title="Size",
    legend_title="Suitability <br>for children"
)
```



Essas proporções podem ser representadas por meio de gráficos de barras lado a lado!

Explorando múltiplas variáveis: contexto multivariados


Ao examinar uma distribuição ou relação entre features, é possível **compará-las entre subgrupos dos dados**.

esse processo resulta em visualizações que envolvem três ou mais variáveis.

Por exemplo, é possível comparar a relação entre `height` e `longevity` nas diferentes categorias de `repetition` que será agrupada de seis categorias para quatro:

```
rep_replacements = {  
    '80-100': '40+', '40-80': '40+',  
    '<5': '<15', '5-15': '<15',  
}  
dogs = dogs.assign(  
    repetition=dogs['repetition'].replace(rep_replacements))
```

```
px.scatter(dogs.dropna(subset=['repetition']), x='height', y='longevity',  
    symbol='repetition', width=450, height=250,  
    labels={'height': 'Height (cm)',  
        'longevity': 'Typical lifespan (yr)',  
        'repetition': 'Repetition'},  
    )
```



Explorando múltiplas variáveis: contexto multivariados


Ao examinar uma distribuição ou relação entre features, é possível **compará-las entre subgrupos dos dados**.

esse processo resulta em visualizações que envolvem três ou mais variáveis.

Por exemplo, é possível comparar a relação entre `height` e `longevity` nas diferentes categorias de `repetition` que será agrupada de seis categorias para quatro:

```
rep_replacements = {  
    '80-100': '40+', '40-80': '40+',  
    '<5': '<15', '5-15': '<15',  
}  
dogs = dogs.assign(  
    repetition=dogs['repetition'].replace(rep_replacements))
```

```
px.scatter(dogs.dropna(subset=['repetition']), x='height', y='longevity',  
    symbol='repetition', width=450, height=250,  
    labels={'height': 'Height (cm)',  
        'longevity': 'Typical lifespan (yr)',  
        'repetition': 'Repetition'},  
    )
```




Cada grupo conta com cerca de 30 raças, e um número menor de categorias facilita identificar as relações!

Explorando múltiplas variáveis: contexto multivariados

Múltiplos gráficos lado a lado (facet plots) oferecem uma abordagem alternativa para exibir essas três características:

```
px.scatter(dogs.dropna(subset=['repetition']),  
           x='height', y='longevity', trendline='ols',  
           facet_col='repetition', facet_col_wrap=2,  
           labels={'height':'Height (cm)',  
                  'longevity':'Typical lifespan (yr)'})
```




Explorando múltiplas variáveis: contexto multivariados

Múltiplos gráficos lado a lado (facet plots) oferecem uma abordagem alternativa para exibir essas três características:

```
px.scatter(dogs.dropna(subset=['repetition']),  
           x='height', y='longevity', trendline='ols',  
           facet_col='repetition', facet_col_wrap=2,  
           labels={'height':'Height (cm)',  
                  'longevity':'Typical lifespan (yr)'})
```

- É possível observar como a relação entre duas variáveis quantitativas varia entre os subgrupos de uma variável qualitativa.
- Raças maiores tendem a ter uma expectativa de vida mais curta.
- As linhas apresentam inclinações semelhantes, mas a linha para "40+" repetições está cerca de 1,5 anos abaixo das demais: *vivem em média, cerca de 1.5 anos a menos!*



Explorando múltiplas variáveis: quantitativo e quantitativo

Gráficos de dispersão são limitados pois são adequados quando há um número relativamente pequeno de valores de dados.

Para conjuntos de dados com **centenas de milhares ou milhões** de registros, um gráfico de dispersão ficará denso demais:

portanto, é necessário uma forma diferente de visualizar essa relação.

Exemplo: considere o conjunto de dados que contém os **valores de avaliação fiscal** de imóveis residenciais no Condado de King, Washington, EUA. Para focar na parte principal dos dados, são **removidas** residências **muito caras** e aquelas **muito pequenas** ou muito grandes utilizando o filtro:

```
TaxAssessedValue< 750000 &
```

```
SqFtTotLiving> 100 & SqFtTotLiving< 3500
```

Explorando múltiplas variáveis: quantitativo e quantitativo

Esse é um **gráfico de compartimentação hexagonal** ou **hexagon binning** da relação entre a área construída (em pés quadrados) e o valor fiscal de imóveis no Condado de King.

- *cada hexágono apresenta uma cor indicando o número de registros naquele compartimento.*
- *existe uma correlação positiva entre a área em pés quadrados (imperial) e o valor fiscal.*
- *Uma característica interessante é o indício de uma **segunda nuvem acima** da nuvem principal, indicando residências que possuem a mesma metragem daquelas na nuvem principal, mas um valor fiscal mais elevado.*





Figure 1-8. Hexagonal binning for tax-assessed value versus finished square feet

Explorando múltiplas variáveis: quantitativo e quantitativo

Curvas de nível sobrepostas a um gráfico de dispersão para visualizar a relação entre duas variáveis numéricas.

Essas curvas funcionam essencialmente como um mapa topográfico das duas variáveis:

- cada **faixa delimitada pelas curvas** representa uma **densidade específica de pontos**, aumentando à medida que se aproxima de um "pico".
- Este gráfico mostra uma situação semelhante à do gráfico anterior, e evidencia que há um **pico secundário ao "norte" do pico principal**.



Explorando múltiplas variáveis: quantitativo e quantitativo

Foi observado que parece haver um grupo de residências com um valor fiscal por pé quadrado (imperial) mais elevado no [gráfico de compartimentação hexagonal anterior](#).

Analisando mais a fundo, o gráfico ao lado explica o **efeito da localização**, apresentando os dados para um conjunto de códigos postais ([ZIP code](#)).

Agora o panorama está muito mais claro:

*o **valor tributável é muito maior** em alguns códigos postais (98112, 98105) do que em outros (98108, 98057).*

Essa disparidade dá origem aos agrupamentos observados na figura de **múltiplos gráficos** ao lado.





Figure 1-12. Tax-assessed value versus finished square feet by zip code

Explorando múltiplas variáveis: quantitativo e quantitativo

Exemplo de **compartimentação hexagonal em Python** dos tempos da corrida por idade do dataset Cherry Blossom em função da idade:

```
runners_over_17 =  
runners[runners["age"] > 17]  
  
plt.figure(figsize=(4, 4))  
  
plt.hexbin(  
    data=runners_over_17, x='age',  
    y='time', gridsize=35,  
    cmap='Blues')  
  
sns.despine()  
plt.grid(False)  
plt.xlabel("Runner age (yr)")  
plt.ylabel("Race time (sec)");
```



Explorando múltiplas variáveis: quantitativo e quantitativo


Gráfico de densidade via KDE também funciona para duas dimensões.

Ao utilizar KDE em duas dimensões, normalmente são traçados as curvas de níveis da forma tridimensional resultante semelhante a um mapa topográfico:

```
plt.figure(figsize=(5, 3))

fig = sns.kdeplot(
    data=runners_over_17,
    x='age',
    y='time')

plt.xlabel("Runner age (yr)")
plt.ylabel("Race time (sec)")
```



TERMOS-CHAVE PARA EXPLORAR DUAS OU MAIS VARIÁVEIS

Tabelas de contingência

Uma contagem de ocorrências entre duas ou mais variáveis categóricas.

Compartimentação ou agrupamento hexagonal

Um gráfico de duas variáveis numéricas com os registros agrupados em hexágonos.

Gráficos de curvas de nível ou de contorno

Um gráfico que mostra a densidade de duas variáveis numéricas, como um mapa topográfico.

Gráficos de violino ou violin plot

Semelhante a um boxplot, mas mostrando a estimativa de densidade.

IDEIAS CHAVE

Compartimentação hexagonal (hexagonal binning) e gráficos de nível (contorno)

são ferramentas úteis que permitem a análise gráfica de duas variáveis numéricas simultaneamente, sem sobrecarregar a visualização com volumes excessivos de dados.

Tabelas de contingência

são a ferramenta padrão para examinar as contagens ou proporções de duas variáveis categóricas.

Boxplots e gráficos de violino

permitem representar uma variável numérica em relação a uma variável categórica.

RESUMO DE TÉCNICAS DE VISUALIZAÇÃO COM MÚLTIPLAS VARIÁVEIS

Duas variáveis quantitativas e uma qualitativa:

Gráfico de dispersão que varia os marcadores de acordo com as categorias da variável qualitativa, ou por meio de painéis de gráficos de dispersão, com um para cada categoria.

Duas variáveis qualitativas e uma quantitativa:

Boxplots lado a lado para comparar a forma básica de uma distribuição entre subgrupos, quando temos duas ou mais variáveis qualitativas, os boxplots podem ser organizados em grupos de acordo com uma dessas variáveis.

RESUMO DE TÉCNICAS DE VISUALIZAÇÃO COM MÚLTIPLAS VARIÁVEIS

Três variáveis quantitativa:

*Técnica parecida ao de duas variáveis quantitativas e uma qualitativa, utiliza-se **gráficos de dispersão lado a lado** para identificar semelhanças entre relações nos diferentes gráficos.*

Três variáveis qualitativas:

*Ao examinar relações entre variáveis qualitativas, as proporções de uma variável dentro de subgrupos definidos por outra podem ser analisados como no exemplo de **gráficos de linhas sobrepostos** ou **gráficos de barras lado a lado**.*

*Com três (ou mais) variáveis qualitativas, é possível continuar subdividindo os dados de acordo com as combinações de níveis das variáveis e comparar essas proporções utilizando gráficos de linhas, gráficos de pontos, gráficos de barras lado a lado, entre outros. **Porém, pode ficar difícil de compreender!***

NOTA

É uma boa prática decompor uma visualização para verificar se uma relação se altera em subgrupos de dados definidos por uma característica qualitativa. Essa técnica é chamada de controle por uma característica.

É possível se surpreender quando, por exemplo, uma relação linear em um gráfico de dispersão, que apresenta uma correlação alta, se inverte para uma correlação baixa em algumas ou para todos os gráficos dos subgrupo.

Esse fenômeno é conhecido como **paradoxo de Simpson!**

Diretrizes para Análise Exploratória de Dados

Durante as etapas de desenvolvimento da análise exploratória de dados, a **criação de gráficos deve ser guiada** pelas seguintes **perguntas**:

- 1. Como os valores da feature X são distribuídos?*
- 2. Como a feature X e a feature Y se relacionam?*
- 3. A distribuição de dados da feature X é a mesma entre os subgrupos definidos pela feature Z ?*
- 4. Existem observações incomuns na feature X ? Na combinação de (X,Y) ? Da feature X para um subgrupo da feature Z ?*

Ao responder a cada uma dessas perguntas, é importante relacionar sua resposta às features e ao contexto.

Adotar uma abordagem ativa e investigativa na análise também é crucial.

Diretrizes para Análise Exploratória de Dados

Para orientar a exploração, faça perguntas do tipo "*qual o próximo passo?*" e "*qual a relevância disso?*", como as seguintes perguntas:

1. *Você tem motivos para esperar que um grupo ou observação seja diferente?*
2. *Por que a sua descoberta sobre a forma da distribuição dos dados pode ser relevante?*
3. *Que comparação adicional poderia agregar valor à investigação exploratória?*
4. *Existem features potencialmente importantes para estabelecer comparações?*

Diretrizes para Análise Exploratória de Dados

Às vezes é **necessário** afastar-se do computador de tempos em tempos para refletir sobre suas descobertas.


Você pode querer **estudar mais** sobre o assunto ou **consultar um especialista** na área do domínio de aplicação do problema para discutir o que encontrou:

*pode haver boas razões para uma observação incomum (**outlier**), e alguém da área pode ajudar a esclarecer a situação e fornecer mais contexto.*

Juntando tudo: **Sumarização Estatística e Visualização de Dados**

Jupyter Notebook Python

Análise do Panorama Geral do Problema



California Housing Prices dataset:

- Baseado nos dados do censo de 1990.
- Apresenta métricas como: população, renda média, preço do imóvel.
- Grupos de blocos ou distritos são a menor unidade geográfica (população entre 600 e 3000 habitantes)

Análise do Panorama Geral do Problema


- A solução deverá aprender com os dados e ser capaz de prever o preço médio do imóvel em qualquer distrito dado o conjunto das outras métricas (features).

- Como a empresa espera utilizar e se beneficiar da solução?

conhecer o objetivo é importante pois ajudará a tratar o problema!

- Como é a solução atual?

a situação atual fornece uma referência para o desempenho e também provê insights importantes de como resolver o problema.




Análise do Panorama Geral do Problema

Features do conjunto de dados:

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   longitude             20640 non-null  float64
1   latitude              20640 non-null  float64
2   housing_median_age    20640 non-null  float64
3   total_rooms           20640 non-null  float64
4   total_bedrooms        20433 non-null  float64
5   population            20640 non-null  float64
6   households            20640 non-null  float64
7   median_income         20640 non-null  float64
8   median_house_value    20640 non-null  float64
9   ocean_proximity       20640 non-null  object
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

Feature do
tipo
categórica!



Manipulação de variáveis categóricas

Manipulação de variáveis categóricas

Em Machine Learning, é essencial converter dados categóricos para dados numéricos para que os algoritmos possam manipulá-los.

Técnicas utilizadas:

- **Ordinal encoding**: cada valor categórico único é mapeado para um valor inteiro.

***Desvantagem** : pode não refletir o relacionamento subjacente entre as variáveis categóricas.*

- **One-hot encoding**: cria features adicionais (**dummy variables**) baseando-se no valor único das variáveis categóricas. Para isso, cria uma **representação binária** para cada variável categórica.

***Desvantagem** : dummy variable trap gera o problema de multicolinearidade.*

Manipulação de variáveis categóricas

Para a variável categórica “*ocean proximity*” pode não ser bem representada com *ordinal encoding*.

<i>Ocean Proximity</i>	<i>Ordinal encoding</i>
<1H OCEAN	0
INLAND	1
ISLAND	2
NEAR BAY	3
NEAR OCEAN	4

Problema: os algoritmos de ML vão assumir que dois valores próximos são mais similares do que dois valores distantes.

Exemplo: categorias 0 e 4 são mais similares do que as categorias 0 e 1.

Manipulação de variáveis categóricas


One-hot encoding: representação binária com adição de dummy variables.

<i>Ocean Proximity</i>	<1H OCEAN	INLAND	ISLAND	NEAR BAY	NEAR OCEAN
<1H OCEAN	1	0	0	0	0
INLAND	0	1	0	0	0
ISLAND	0	0	1	0	0
NEAR BAY	0	0	0	1	0
NEAR OCEAN	0	0	0	0	1

Problema: *dummy variable trap* ou multicolinearidade.

Manipulação de variáveis categóricas

Problema: *dummy variable trap* gera o problema de **multicolinearidade** que ocorre quando duas ou mais *features* são **altamente correlacionadas** ou quando duas ou mais *features* **podem prever** outra *feature*.




isSmall	isMedium	isLarge		Sum
1	0	0	→	1
0	1	0		1
0	0	1		1

$isSmall + isMedium + isLarge = 1$

Manipulação de variáveis categóricas

Solução:



Manipulação de variáveis categóricas

Contagem de quantas instâncias existem para cada categoria de `ocean_proximity`:

```
df['ocean_proximity'].value_counts()
```

...

	count
--	-------

ocean_proximity	count
-----------------	-------

<1H OCEAN	9136
-----------	------


INLAND	6551
--------	------

NEAR OCEAN	2658
------------	------


NEAR BAY	2290
----------	------

ISLAND	5
--------	---


dtype: int64




Sumarização Estatística: visualização de múltiplas variáveis




Sumarização Estatística: visualização de múltiplas variáveis



Sumarização Estatística: visualização de múltiplas variáveis



Sumarização Estatística: visualização de múltiplas variáveis



Sumarização Estatística

Perguntas para guiar a **visualização de múltiplas variáveis**, se as observações fossem agrupadas por `ocean_proximity`:

1. *Como estaria distribuído o valor médio do imóvel (histogramas e gráficos de densidade)?*
2. *Como estaria distribuído a idade média do imóvel (histogramas e gráficos de densidade)?*
3. *Ao examinar a relação entre feature as features `median_house_value` e `median_income` é possível separá-las em subgrupos de `ocean_proximity`?*
4. *Ao examinar a relação entre feature as features `population` e `total_bedrooms` é possível separá-las em subgrupos de `ocean_proximity`?*
5. *Comparando os gráficos de múltiplas visualizações é possível observar novos insights? **Diferenças nas distribuições** ou possível **Paradoxo de Simpson** nos gráficos de dispersão.*

Bibliografia

[Bruce, Bruce & Gedek] Bruce, Peter; Bruce, Andrew; Gedeck, Peter. **Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python**. 2nd ed. California, USA: O'Reilly Media, 2020.

[Downey, 2025] Downey, Allen B.. **Think Stats: Exploratory Data Analysis**. California, USA: O'Reilly Media, 2025.

[Géron, 2022] Géron, Aurélien. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**. O'Reilly, 2022.

[Lau, Gonzalez & Nolan, 2023] Lau, Sam; Gonzalez, Joseph; Nolan, Deborah. **Learning Data Science: Data Wrangling, Exploration, Visualization, and Modeling with Python**. California, USA: O'Reilly Media, 2023.

[VanderPlas, 2016] VanderPlas, Jake. **Python Data Science Handbook: Essential Tools for Working with Data**. California, USA: O'Reilly Media, 2016.