

Estatística Descritiva e Visualização de Dados

Professor: Alexandre Magno de Sousa

Curso de Especialização em Ciência de Dados

Departamento de Computação e Sistemas - DECSI

Instituto de Ciências Exatas e Aplicadas - ICEA

Universidade Federal de Ouro Preto - UFOP

Sumário

Diretrizes para Análise Exploratória de Dados

Abordagem ativa e inquisitiva para investigação

Escopo dos dados

Análise exploratória guiada por meio de perguntas

Explorando as perguntas do problema

Como contar histórias com dados

Princípios de percepção visual


Guia prático em seis lições: exemplo

*The first principle is that you must not fool yourself — and you are
the easiest person to fool.*
— Richard Feynman

Cronograma

Conteúdo	Data
Sumarização Estatística: tipos de dados, medidas de localização, dispersão, forma e de associação.	01/07/2026
Visualização de distribuições: tipos de gráficos e elementos visuais, conectando visualização com sumarização.	04/07/2026
Sumarização e visualização de categóricos & variáveis múltiplas: dados binários e categóricos, múltiplas variáveis.	08/07/2026
Princípios e narrativas da Análise Exploratória de Dados: diretrizes para EDA e como contar histórias com dados.	11/07/2026

Boa parte do tempo....



O que é Visualização dos dados?

Estatística Descritiva é o ramo da estatística responsável por **organizar**, **resumir** e **descrever** os principais aspectos de um conjunto de dados.

Visualização de dados é o processo de transformar dados brutos e complexos em **elementos visuais/formatos visuais**, como gráficos, mapas e painéis interativos.

Diretrizes para Análise Exploratória de Dados

Durante as etapas de desenvolvimento da análise exploratória de dados, a **criação de gráficos deve ser guiada** pelas seguintes **perguntas**:

- 1. Como os valores da feature X são distribuídos?*
- 2. Como a feature X e a feature Y se relacionam?*
- 3. A distribuição de dados da feature X é a mesma entre os subgrupos definidos pela feature Z ?*
- 4. Existem observações incomuns na feature X ? Na combinação de (X,Y) ? Da feature X para um subgrupo da feature Z ?*

Ao responder a cada uma dessas perguntas, é importante relacionar sua resposta às features e ao contexto.

Adotar uma abordagem ativa e investigativa na análise também é crucial.

Diretrizes para Análise Exploratória de Dados

Para orientar a exploração, faça perguntas do tipo "*qual o próximo passo?*" e "*qual a relevância disso?*", como as seguintes perguntas:

1. *Você tem motivos para esperar que um grupo ou observação seja diferente?*
2. *Por que a sua descoberta sobre a forma da distribuição dos dados pode ser relevante?*
3. *Que comparação adicional poderia agregar valor à investigação exploratória?*
4. *Existem features potencialmente importantes para estabelecer comparações?*

Diretrizes para Análise Exploratória de Dados

Às vezes é **necessário** afastar-se do computador de tempos em tempos para refletir sobre suas descobertas.

Você pode querer **estudar mais** sobre o assunto ou **consultar um especialista** na área do domínio de aplicação do problema para discutir o que encontrou:

*pode haver boas razões para uma observação incomum (**outlier**), e alguém da área pode ajudar a esclarecer a situação e fornecer mais contexto.*

Diretrizes para Análise Exploratória de Dados

Variáveis categóricas frequentemente revelam padrões relacionados a comportamento, grupos ou estrutura nos dados.

Examinar sua *frequência, equilíbrio/balanceamento e relação com outras variáveis* pode revelar tendências que a sumarização estatística, por si só, não conseguem mostrar!

Diretrizes para Análise Exploratória de Dados

Ao explorar dados categóricos, é útil fazer perguntas simples:

- 1. Quais categorias são mais comuns?*
- 2. Existem categorias sub-representadas ou raramente observadas?*
- 3. Os resultados diferem entre as categorias?*
- 4. Existem categorias com desempenho excepcionalmente alto ou baixo?*
- 5. Certas categorias dominam o conjunto de dados e influenciam os resultados gerais?*
- 6. Existem categorias com rótulos ausentes ou pouco claros?*

Diretrizes para Análise Exploratória de Dados: escopo dos dados

Dataset do San Francisco Chronicle.

- *Período: abril de 2003 e dezembro de 2008.*
- *Cada registro representa uma venda:*
 - *Se a casa foi vendida 2 vezes, haverá 2 registros.*
 - *Se a casa não foi colocada a venda, o registro não aparece.*

Diretrizes para Análise Exploratória de Dados: escopo dos dados

	city	zip	street	price	br	lsqft	bsqft	timestamp
0	Alameda	94501.0	1001 Post Street	689000.0	4.0	4484.0	1982.0	2004-08-29
1	Alameda	94501.0	1001 Santa Clara Avenue	880000.0	7.0	5914.0	3866.0	2005-11-06
2	Alameda	94501.0	1001 Shoreline Drive W#102	393000.0	2.0	39353.0	1360.0	2003-09-21
...	...	...	...	...	...	...	...	...
521488	Windsor	95492.0	9998 Blasi Drive	392500.0	NaN	3111.0	NaN	2008-02-17
521489	Windsor	95492.0	9999 Blasi Drive	414000.0	NaN	2915.0	NaN	2008-02-17
521490	Windsor	95492.0	999 Gemini Drive	325000.0	3.0	7841.0	1092.0	2003-09-21

521491 rows × 8 columns

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 521491 entries, 0 to 521490
Data columns (total 8 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   city        521491 non-null object
1   zip         521462 non-null float64
2   street      521479 non-null object
3   price       521491 non-null float64
4   br          421343 non-null float64
5   lsqft       435207 non-null float64
6   bsqft       444465 non-null float64
7   timestamp   521491 non-null datetime64[ns]
dtypes: datetime64[ns](1), float64(5), object(2)
memory usage: 31.8+ MB
```

Diretrizes para Análise Exploratória de Dados: escopo dos dados

A chave primária consiste na combinação de `city`, `ZIP`, `street` e `timestamp`.

A variável `price`, preço de venda, é o nosso foco, sendo assim, vamos começar explorando a sua distribuição.

Como os valores da feature `price` são distribuídos?

Diretrizes para Análise Exploratória de Dados: Exemplo

Uma suposição para o formato da distribuição dos preços de venda é que ela seja **right skewed**, com algumas poucas casas muito caras.

```
percs = [0, 25, 50, 75, 100]
prices = np.percentile(sfh_df['price'], percs, method='lower')
pd.DataFrame({'price': prices}, index=percs)
```

	price
0	22000.00
25	410000.00
50	555000.00
75	744000.00
100	2000000.00

```
percs = [95, 97, 98, 99, 99.5, 99.9]
prices = np.percentile(sfh_df['price'], percs, method='lower')
pd.DataFrame({'price': prices}, index=percs)
```

	price
95.00	1295000.00
97.00	1508000.00
98.00	1707000.00
99.00	2110000.00
99.50	2600000.00
99.90	3950000.00


- 99,9% das casas foram vendidas por menos de US\$ 4 milhões.
- A venda por **US\$ 20 milhões** é, de fato, uma raridade (*outlier*)!

Diretrizes para Análise Exploratória de Dados: Exemplo

Vamos examinar o histograma dos preços de venda abaixo de **US\$ 4 milhões**:

```
under_4m = sfh_df[sfh_df['price'] < 4_000_000].copy()
```

```
px.histogram(under_4m, x='price', nbins=50, width=350, height=250,  
             labels={'price': 'Sale price (USD)'})
```




Diretrizes para Análise Exploratória de Dados: Exemplo

Vamos examinar o histograma dos preços de venda abaixo de US\$ 4 milhões:

```
under_4m['log_price'] = np.log10(under_4m['price'])
```

```
px.histogram(under_4m, x='log_price', nbins=50, width=350, height=250,  
             labels={'log_price': 'Sale price (log10 USD)'})
```



A distribuição do preço de venda com a aplicação da transformação logarítmica é aproximadamente simétrica.

Diretrizes para Análise Exploratória de Dados: Exemplo

Precisamos considerar por que esse formato é relevante e buscar grupos de comparação nos quais as distribuições possam diferir.

Modelos e estatísticas baseados em distribuições simétricas tendem a apresentar propriedades mais robustas e estáveis.

A análise de preços de venda pode ser limitada a valores $< \text{US\$ } 4 \text{ milhões}$, uma vez que as casas de altíssimo valor são outliers.

O mercado imobiliário cresceu rapidamente durante esse período e, em seguida, sofreu um colapso.

A distribuição dos preços de venda em 2004 pode ser bem diferente daquela de 2008, pouco antes da quebra do mercado (bolha imobiliária).

Diretrizes para Análise Exploratória de Dados: Exemplo

Restringimos os dados às vendas realizadas somente em 2004:

a alta dos preços deve ter um impacto limitado nas distribuições e relações que serão analisadas.

Para limitar a influência de *outliers* ou casas muito grandes e de valores muito altos:

restringimos o dataset à vendas <US\$ 4 milhões e casas com área <2.000 pés quadrados.

```
def subset(df):  
    return df.loc[(df['price'] < 4_000_000) &  
                  (df['bsqft'] < 12_000) &  
                  (df['timestamp'].dt.year == 2004)]
```

```
sfh = sfh_df.pipe(subset)  
sfh
```

	city	zip	street	price	br	lsqft	bsqft	timestamp
0	Alameda	94501.00	1001 Post Street	689000.00	4.00	4484.00	1982.00	2004-08-29
3	Alameda	94501.00	1001 Shoreline Drive W#108	485000.00	2.00	39353.00	1360.00	2004-09-05
10	Alameda	94501.00	1001 Shoreline Drive W#306	390000.00	2.00	39353.00	1360.00	2004-01-25
...	...	...	...	...	...	...	...	...
521467	Windsor	95492.00	9960 Herb Road	439000.00	3.00	9583.00	1626.00	2004-04-04
521471	Windsor	95492.00	9964 Troon Court	1200000.00	3.00	20038.00	4281.00	2004-10-31
521478	Windsor	95492.00	9980 Brooks Road	650000.00	3.00	45738.00	1200.00	2004-10-24

105996 rows × 8 columns

A forma da distribuição do preço de venda permanece o mesmo, ou seja, continua right skewed!

Como a feature $lsqft$ e a feature $bsqft$ se relacionam?

Diretrizes para Análise Exploratória de Dados: Exemplo

Outras features também podem ser importantes: `bsqft` e `lsqft`.


O tamanho da casa e do terreno provavelmente estão relacionados ao seu preço:

*é esperado que também seja **right skewed**!*

```
sfh = sfh.assign(log_bsqft=np.log10(sfh['bsqft']))
```

```
fig = make_subplots(1,2)
fig.add_trace(go.Histogram(x=sfh['bsqft'], histnorm='percent',
                           nbinsx=60), row=1, col=1)
fig.add_trace(go.Histogram(x=sfh['log_bsqft'], histnorm='percent',
                           nbinsx=60), row=1, col=2)



fig.update_xaxes(title='Building size (ft²)', row=1, col=1)
fig.update_xaxes(title='Building size (ft², log10)', row=1, col=2)
fig.update_yaxes(title="percent", row=1, col=1)
fig.update_yaxes(range=[0, 18])
fig.update_layout(width=450, height=250, showlegend=False)
fig
```



Diretrizes para Análise Exploratória de Dados: Exemplo

Dado que tanto `bsqft` quanto o `lsqft` apresentam distribuições assimétricas, um **gráfico de dispersão** de ambos também deve utilizar uma **escala logarítmica**:

```
sfh = sfh.assign(log_lsqft=np.log10(sfh['lsqft']))
```



Existem observações incomuns na feature $lsqft$?

Existem observações incomuns na combinação de $(lsqft, bsqft)$?



Existem observações incomuns na feature br ?

Diretrizes para Análise Exploratória de Dados: Exemplo

Dado que tanto `bsqft` quanto o `lsqft` apresentam distribuições assimétricas, um **gráfico de dispersão** de ambos também deve utilizar uma **escala logarítmica**:

```
sfh = sfh.assign(log_lsqft=np.log10(sfh['lsqft']))
```


relacionamento log-log linear



Diretrizes para Análise Exploratória de Dados: Exemplo

Vamos examinar alguns quantis inferiores do `lsqft` para tentar entender esse valor incomum:

2.64



```
percs = [0.5, 1, 1.5, 2, 2.5, 3]
lots = np.percentile(sfh['lsqft'].dropna(), percs, method='lower')
pd.DataFrame({'lot_size': lots}, index=percs)
```

	lot_size
0.50	436.00
1.00	436.00
1.50	436.00
2.00	436.00
2.50	436.00
3.00	782.00

Cerca de 2,5% das casas têm um tamanho de terreno de 436 pés quadrados:

$$\text{Log}_{10}(436) \approx 2.64$$


Isso faz pouco sentido, por isso esse outlier deve ser investigado posteriormente.

Diretrizes para Análise Exploratória de Dados: Exemplo

Outra medida do tamanho da casa é `br` (número de quartos).

Como se trata de uma **variável quantitativa discreta**, ela pode ser tratada como uma **variável qualitativa** e analisada com um **gráfico de barras**.

```
br_cat = sfh['br'].value_counts().reset_index()
px.bar(br_cat, x="br", y="count", width=350, height=250,
       labels={'br': 'Number of bedrooms'})
```




Isso aponta para outro possível problema de qualidade dos dados!

Diretrizes para Análise Exploratória de Dados: Exemplo

Vamos transformar o número de quartos em uma **variável ordinal** e atribuir todos os valores superiores a 8 para "8+" e recriar o gráfico de barras:

```
eight_up = sfh.loc[sfh['br'] >= 8, 'br'].unique()
sfh['new_br'] = sfh['br'].replace(eight_up, 8)

br_cat = sfh['new_br'].value_counts().reset_index()
px.bar(br_cat, x="new_br", y="count", width=350, height=250,
       labels={'new_br': 'Number of bedrooms'})
```



Há uma assimetria, com algumas casas apresentando seis ou mais quartos.

Diretrizes para Análise Exploratória de Dados: Exemplo

Até agora temos as seguintes transformações:


```
def log_vals(df):  
    return df.assign(log_price=np.log10(df['price']),  
                     log_bsqft=np.log10(df['bsqft']),  
                     log_lsqft=np.log10(df['lsqft']))  
  
def clip_br(df):  
    eight_up = df.loc[df['br'] >= 8, 'br'].unique()  
    new_br = df['br'].replace(eight_up, 8)  
    return df.assign(new_br=new_br)  
  
sfh = (sfh_df  
      .pipe(subset)  
      .pipe(log_vals)  
      .pipe(clip_br)  
      )
```

A distribuição de dados da feature `price` é a mesma entre os subgrupos definidos pela feature `br` (número de quartos)?

Diretrizes para Análise Exploratória de Dados: Exemplo

Vamos começar examinando a distribuição das variações de preço de casas com diferentes `br` (números de quartos):

```
px.box(sfh, x='new_br', y='price', log_y=True, width=450, height=250,  
      labels={'new_br': 'Number of bedrooms', 'price': 'Sale price (USD)'})
```




Diretrizes para Análise Exploratória de Dados: Exemplo

Consideramos um tipo de transformação que divide o preço pelo tamanho da edificação para obter o **preço por pé quadrado**.


Queremos verificar se essa variável é constante para todas as casas, isto é, *se o preço é determinado principalmente pelo tamanho*.

Analisamos a relação entre os dois pares de tamanho e preço, e entre preço por pé quadrado e tamanho:

```
sfh = sfh.assign(  
    ppsf=sfh['price'] / sfh['bsqft'],  
    log_ppsf=lambda df: np.log10(df['ppsf']))
```



Diretrizes para Análise Exploratória de Dados: Exemplo



- Casas maiores, custam mais.
- Relacionamento **log-log**!

- Relacionamento **não linear**!
- Casas menores custam mais por pé quadrado do que as maiores.
- O preço por pé quadrado das casas maiores permanece relativamente estável.

Diretrizes para Análise Exploratória de Dados: Exemplo

A variável adicionada preço por pé quadrado (`ppsf`) parece ser interessante, então, até agora temos:

```
def subset(df):  
    return df.loc[(df['price'] < 4_000_000) &  
                  (df['bsqft'] < 12_000) &  
                  (df['timestamp'].dt.year == 2004)]
```

```
def log_vals(df):  
    return df.assign(log_price=np.log10(df['price']),  
                    log_bsqft=np.log10(df['bsqft']),  
                    log_lsqt=np.log10(df['lsqft']))
```

```
def clip_br(df):  
    eight_up = df.loc[df['br'] >= 8, 'br'].unique()  
    new_br = df['br'].replace(eight_up, 8)  
    return df.assign(new_br=new_br)
```

```
def compute_ppsf(df):  
    return df.assign(  
        ppsf=df['price'] / df['bsqft'],  
        log_ppsf=lambda df: np.log10(df['ppsf']))
```

```
sfh = (sfh_df  
      .pipe(subset)  
      .pipe(log_vals)  
      .pipe(clip_br)  
      .pipe(compute_ppsf)  
      )
```

Existem observações incomuns da feature `price` para um subgrupo da feature `city`?

Diretrizes para Análise Exploratória de Dados: Exemplo

Você talvez já tenha ouvido a expressão:


há três coisas que importam no mercado imobiliário: localização, localização, localização.

Comparar preços entre cidades pode trazer **insights adicionais** para a nossa investigação.


Analizamos dados de algumas cidades da **região de East Bay** em São Francisco:

Richmond, El Cerrito, Albany, Berkeley, Walnut Creek, Lamorinda e Piedmont.

```
cities = ['Richmond', 'El Cerrito', 'Albany', 'Berkeley',  
         'Walnut Creek', 'Lamorinda', 'Piedmont']  
  
px.box(sfh.query('city in @cities'), x='city', y='price',  
       log_y=True, width=450, height=250,  
       labels={'city': '', 'price': 'Sale price (USD)'})
```



Diretrizes para Análise Exploratória de Dados: Exemplo




Diretrizes para Análise Exploratória de Dados: Exemplo


Vamos examinar mais de perto a relação entre o **preço por pé quadrado** e o **tamanho** da casa utilizando gráficos de dispersão:

```
four_cities = ["Berkeley", "Lamorinda", "Piedmont", "Richmond"]
fig = px.scatter(sfh.query("city in @four_cities"),
                 x="bsqft", y="log_ppsf", facet_col="city", facet_col_wrap=2,
                 labels={'bsqft': 'Building size (ft^2)',
                        'log_ppsf': "Price per square foot"},
                 trendline="ols", trendline_color_override="black",
                 )

fig.update_layout(xaxis_range=[0, 5500], yaxis_range=[1.5, 3.5],
                  width=450, height=400)
fig.show()
```



Diretrizes para Análise Exploratória de Dados: Exemplo



Observações:

1. A relação é aproximadamente **log-linear** com uma **associação negativa**.
2. Existe uma **valorização associada à localização**:
uma casa em Berkeley custa em média mais do que uma casa em Richmond.
3. Em cidades mais caras, como Lamorinda e Piedmont:

***não ocorre** a mesma **redução no preço por pé quadrado** para casas maiores em comparação com as menores.*

Diretrizes para Análise Exploratória de Dados: Exemplo

Dados coletados entre 2003 e 2008 e mostram o colapso da bolha imobiliária dos EUA em 2008/2009: **série temporal** da mediana dos valores dos preços dos imóveis.

```
sfh_labels={'price':"Sale price (USD)", 'date':""}  
medians = rel_percentiles.query('percentile == 50')  
fig = px.line(medians, x='date', y='price',  
              title='Median sale price',  
              labels=sfh_labels,  
              width=500, height=250)  
margin(fig, t=30)
```



Diretrizes para Análise Exploratória de Dados: Exemplo

Ao analisar os preços ao longo do tempo, geralmente é preciso fazer **ajustes para a inflação**, a fim de que as comparações sejam feitas em pé de igualdade.

Além de realizar o ajuste pela inflação, vamos traçar os preços em relação ao preço inicial de 2003 para cada um dos percentis: **10º, 30º, 50º (mediana), 70º e 90º-percentis**.

Isso significa que todas as linhas começam em $y = 1$ em 2003:

***Exemplo** : um valor de 1.5 para o 90º percentil em 2006 indica que o preço de venda é 1.5 vezes o 90º percentil em 2003.*

Essa **normalização** nos permite ver como a crise do mercado imobiliário afetou os proprietários de imóveis nos diferentes segmentos do mercado.


Diretrizes para Análise Exploratória de Dados: Exemplo

A linha do 10º percentil aumenta rapidamente em 2005, permanece elevada por alguns anos, e, em seguida, cai mais cedo e mais rapidamente:

isso mostra que as casas mais baratas sofreram maior volatilidade e perderam muito mais valor durante o colapso do mercado imobiliário.

Em contrapartida, as residências de alto padrão foram menos afetadas pela quebra do mercado:

no final de 2008, os preços dos imóveis situados no 90º percentil ainda eram superiores aos de 2003.



Diretrizes para Análise Exploratória de Dados: Exemplo

- O preço de venda e o tamanho da construção apresentam uma **distribuição unimodal** com forte **assimetria à direita** (*right skewed*).
- O preço por pé quadrado **diminui** de forma **não linear** em relação ao tamanho da construção:

casas menores têm um custo por pé quadrado mais elevado do que as maiores, enquanto, para casas grandes, esse valor permanece praticamente constante.


- **Localizações mais desejáveis** acrescentam um **valor adicional** ao preço de venda que é aproximadamente o mesmo para casas de diferentes tamanhos.
- **Análises adicionais** ainda precisam ser feitas:

confrontar informações sobre casas incomuns com aplicativos imobiliários online (casa com 30 quartos e a de US\$ 20 milhões) e o terreno de 436 pés quadrados.

What is the question?

- Confundir o tipo de pergunta em análise é o erro mais comum na análise de dados.
- Conectando perguntas com o tipo de análise necessária.

Data analysis flowchart



Como contar histórias com dados

Princípios de percepção visual

Carga cognitiva é o **esforço mental** exigido para aprender novas informações.

Exemplo: *ao assistir uma apresentação de slides carregada e complicada, ao ler um relatório com um gráfico que chama a atenção mas é difícil de entender.*

Relação **Sinal-Ruído**:

*O **sinal** é a **informação** que queremos comunicar e o **ruído** são os **elementos** que **adicionamos** ou, em alguns casos, **reduzimos** da mensagem que estamos tentando transmitir para o público.*

Princípios de percepção visual

O que mais importa é a **carga cognitiva percebida** por parte do público:

o quanto ele acredita que precisará se esforçar para entender a informação de sua comunicação.

Você deve **minimizar** a **carga cognitiva** percebida ao que seja razoável e ainda permita transmitir a informação.

Um dos culpados que podem contribuir para a **carga cognitiva excessiva** ou extrínseca é algo que chamo simplesmente de **saturação**:

elementos visuais que ocupam espaço, mas não aumentam o entendimento.

A **saturação** pode fazer algo parecer **mais complicado** do que realmente é.

Princípios de percepção visual

A **Escola de Psicologia Gestalt** começou no início dos anos 1900 para entender como as pessoas percebem a ordem no mundo ao redor.

Princípios da Gestalt de Percepção Visual:

*ajuda a identificar quais elementos visuais são **sin**al (informação) e quais podem ser **ruído** (saturação).*

Existem **seis princípios**:

- | | |
|-----------------|-----------------|
| 1. Proximidade | 4. Fechamento |
| 2. Similaridade | 5. Continuidade |
| 3. Acercamento | 6. Conexão |

Princípios de percepção visual: Proximidade

O ser humano tende a pensar que objetos fisicamente próximos fazem parte de um grupo.



FIGURA 3.1 PRINCÍPIO DA PROXIMIDADE DA GESTALT



FIGURA 3.2 VOCÊ VÊ COLUNAS E LINHAS SIMPLEMENTE POR CAUSA DO ESPAÇAMENTO ENTRE OS PONTOS

Isso pode ser aproveitado na forma como as pessoas veem design de tabelas.

Princípios de percepção visual: Proximidade

O ser humano tende a pensar que objetos fisicamente próximos fazem parte de um grupo.




FIGURA 3.1 PRINCÍPIO DA PROXIMIDADE DA GESTALT



FIGURA 3.2 VOCÊ VÊ COLUNAS E LINHAS SIMPLEMENTE POR CAUSA DO ESPAÇAMENTO ENTRE OS PONTOS

Isso pode ser aproveitado na forma como as pessoas veem design de tabelas.

Princípios de percepção visual: Proximidade

O ser humano tende a pensar que objetos fisicamente próximos fazem parte de um grupo.




FIGURA 3.1 PRINCÍPIO DA PROXIMIDADE DA GESTALT




FIGURA 3.2 VOCÊ VÊ COLUNAS E LINHAS SIMPLEMENTE POR CAUSA DO ESPAÇAMENTO ENTRE OS PONTOS

Isso pode ser aproveitado na forma como as pessoas veem design de tabelas.

Princípios de percepção visual: Similaridade

Objetos que têm cor, forma, tamanho ou orientação semelhantes são percebidos como relacionados ou pertencentes a parte de um grupo.



FIGURA 3.3 PRINCÍPIO DA SIMILARIDADE DA GESTALT



FIGURA 3.4 VOCÊ VÊ LINHAS DEVIDO À SIMILARIDADE DA COR

Isso pode ser aproveitado em tabelas, para ajudar a chamar a atenção do público para onde queremos focar.

Princípios de percepção visual: Similaridade

Objetos que têm cor, forma, tamanho ou orientação semelhantes são percebidos como relacionados ou pertencentes a parte de um grupo.



FIGURA 3.3 PRINCÍPIO DA SIMILARIDADE DA GESTALT



FIGURA 3.4 VOCÊ VÊ LINHAS DEVIDO À SIMILARIDADE DA COR

Isso pode ser aproveitado em tabelas, para ajudar a chamar a atenção do público para onde queremos focar.

Princípios de percepção visual: Similaridade

Objetos que têm cor, forma, tamanho ou orientação semelhantes são percebidos como relacionados ou pertencentes a parte de um grupo.



FIGURA 3.3 PRINCÍPIO DA SIMILARIDADE DA GESTALT




FIGURA 3.4 VOCÊ VÊ LINHAS DEVIDO À SIMILARIDADE DA COR

Isso pode ser aproveitado em tabelas, para ajudar a chamar a atenção do público para onde queremos focar.

Princípios de percepção visual: Acercamento

As pessoas acham que objetos fisicamente delimitados fazem parte de um grupo.



FIGURA 3.5 PRINCÍPIO DO ACERCAMENTO DA GESTALT




FIGURA 3.6 A ÁREA SOMBREADA SEPARA A PREVISÃO DOS DADOS REAIS

Um modo de aproveitar o princípio do acercamento é traçar uma distinção visual dentro dos gráficos.

Princípios de percepção visual: Fechamento

O conceito do fechamento diz que as pessoas gostam que as coisas sejam simples e se encaixem nas construções que já estão em nossas mentes.

Por isso, tendem a perceber um conjunto de elementos individuais como uma única forma reconhecível, quando partes de um todo estão faltando, nossos olhos preenchem as lacunas.



FIGURA 3.7 PRINCÍPIO DO FECHAMENTO DA GESTALT




FIGURA 3.8 O GRÁFICO AINDA PARECE COMPLETO SEM A BORDA E O SOMBREADO DE FUNDO



É comum os aplicativos/bibliotecas de geração de gráficos terem configurações padrão que incluem elementos como bordas e sombreado de fundo.

Princípios de percepção visual: Continuidade

É semelhante ao do fechamento: ao olhar os objetos, nossos olhos buscam o caminho mais suave e criam continuidade no que vemos naturalmente, mesmo onde ela pode não existir explicitamente.



FIGURA 3.9 PRINCÍPIOS DA CONTINUIDADE DA GESTALT



FIGURA 3.10 GRÁFICO COM A LINHA DO EIXO Y REMOVIDA

Mesmo com a remoção da linha vertical do eixo y, seus olhos ainda vêem que as barras estão alinhadas no mesmo ponto, graças ao espaço em branco uniforme entre as legendas e as barras.

Princípios de percepção visual: Conexão

As pessoas tendem a considerar objetos fisicamente conectados como parte de um grupo.

A propriedade conectiva normalmente tem um valor associativo mais forte do que cor, tamanho ou forma similar.




FIGURA 3.11 PRINCÍPIO DA CONEXÃO DA GESTALT




FIGURA 3.12 LINHAS CONECTAM OS PONTOS

Um modo frequente de usar esse princípio é em gráficos de linhas, para ajudar nossos olhos a ver ordem nos dados.

Removendo a Saturação: exemplo

Cenário:

Imagine que você gerencia uma equipe de tecnologia da informação (TI). Sua equipe recebe tíquetes, ou questões técnicas, dos funcionários. No ano passado, duas pessoas saíram da equipe e, na época, você decidiu não substituí-las.

Você tem ouvido rumorosas reclamações dos demais funcionários sobre terem de “preencher a lacuna”. Recentemente, você foi questionado sobre suas necessidades de contratação para o próximo ano e está se perguntando se deve contratar mais duas pessoas.

Primeiro, você quer entender o impacto que a saída das pessoas no ano passado teve na produtividade global de sua equipe. Você coloca em um gráfico a tendência mensal dos tíquetes recebidos e aqueles processados no ano passado.

Você vê que há certa evidência de que a produtividade de sua equipe está sendo prejudicada pela falta de pessoal e agora quer tornar o visual que criou a base para seu pedido de contratação.

Removendo a Saturação: exemplo




FIGURA 3.17 GRÁFICO ORIGINAL

- Examine novamente esse visual, prestando atenção na saturação.
- Considere as lições que abordamos sobre os princípios da Gestalt.
- Do que podemos nos desfazer ou alterar? Quantos problemas você consegue identificar?

Removendo a Saturação: exemplo

1. **Remova a borda do gráfico:** as bordas de gráfico normalmente são desnecessárias, conforme abordamos em nossa discussão sobre o **princípio do fechamento** da Gestalt.




FIGURA 3.18 REMOVA AS BORDAS DO GRÁFICO

Removendo a Saturação: exemplo

2. **Remova as linhas de grade:** não permita que elas concorram visualmente com os dados, use cores distintas para cada linha do gráfico. Quando puder, desfaça-se delas completamente: isso permite um maior contraste e seus dados se destacarão mais.




FIGURA 3.19 REMOVA AS LINHAS DE GRADE

Removendo a Saturação: exemplo

3. **Remova marcadores de dados:** lembre-se que cada elemento acrescenta carga cognitiva por parte de seu público. Aqui, estamos adicionando carga cognitiva para processar dados que já estão representados visualmente pelas linhas.





FIGURA 3.20 REMOVA OS MARCADORES DE DADOS

Removendo a Saturação: exemplo

4. **Limpe as legendas de eixo**: um de meus maiores aborrecimentos são os zeros à direita em legendas no eixo y: eles não transmitem nenhum valor informativo. Também podemos abreviar os meses do ano para que se encaixem no eixo x, eliminando o texto diagonal.



Removendo a Saturação: exemplo

5. **Legende os dados diretamente:** lembre-se queremos identificar tudo que pareça esforço para nosso público e assumir nossa responsabilidade como designers da informação. Neste caso, podemos usar o **princípio da proximidade** da Gestalt e colocar as legendas bem perto dos dados que elas descrevem.




FIGURA 3.22 LEGENDE OS DADOS DIRETAMENTE

Removendo a Saturação: exemplo

6. **Potencialize cores consistentes:** vamos pensar também em usar o princípio da similaridade e deixar as legendas da mesma cor que os dados que elas descrevem. Esse é outra dica visual para nosso público, que diz, “essas duas informações estão relacionadas”. Você pode usar uma cor para destacar a informação que mais interessa ou duas cores diferentes e contrastantes.




FIGURA 3.23 USE CORES CONSISTENTES

Removendo a Saturação: exemplo

- Esse visual ainda não está completo.
- Mas identificar e eliminar a saturação nos fez andar bastante no sentido de reduzir a carga cognitiva e melhorar a acessibilidade.
- Veja o antes e depois:





FIGURA 3.24 ANTES E DEPOIS

Guia prático em seis lições

As seis lições importantes:

- **Lição 1:** Entenda o *contexto*.
- **Lição 2:** Escolha a *apresentação visual* adequada.
- **Lição 3:** Elimine a *saturação*.
- **Lição 4:** Foque a *atenção* onde você deseja.
- **Lição 5:** Pense como um *designer*.
- **Lição 6:** Conte uma *história*.

Guia prático em seis lições




FIGURA 8.1 VISUAL ORIGINAL

Preço de revenda médio no decorrer do tempo de cinco produtos (A, B, C, D e E).

Guia prático em seis lições: Lição 1 - Entenda o contexto

Entendimento do contexto e do que você precisa comunicar:

- *vamos supor que trabalhamos em uma startup que criou um produto para o consumidor.*
- *estamos começando a pensar no preço que o produto deve ter.*
- *O preço declinou para todos os produtos no mercado desde o lançamento do produto C em 2010.*

Guia prático em seis lições: Lição 1 - Entenda o contexto

Quem, o quê e como:

- **Quem:** vice-presidente do produto, o principal tomador de decisão na empresa do preço de nosso produto.
- **O quê:** entender como os preços dos concorrentes mudaram no decorrer do tempo e recomendar uma faixa de preço.
- **Como:** mostrar o preço médio no varejo no decorrer do tempo dos produtos A, B, C, D e E.

Com base na análise dos preços no mercado no decorrer do tempo, para sermos competitivos, recomendamos introduzir nosso produto a um preço de varejo na faixa de R\$ABC a R\$XYZ.

Guia prático em seis lições: Lição 2 - Escolha um visual apropriado

Estamos mais interessados na tendência do preço no decorrer do tempo para cada produto.

A variação nas cores entre as barras desvia a atenção disso.




FIGURA 8.1 VISUAL ORIGINAL

Guia prático em seis lições: Lição 2 - Escolha um visual apropriado

Vamos remover o obstáculo visual da variação na cor e ver o gráfico resultante.




FIGURA 8.2 REMOVA A VARIAÇÃO NA COR

Guia prático em seis lições: Lição 2 - Escolha um visual apropriado

Foco: o que aconteceu desde que o produto C foi lançado em 2010?

vamos realçar os dados relevantes!




FIGURA 8.3 ENFATIZE DE 2010 EM DIANTE

Guia prático em seis lições: Lição 2 - Escolha um visual apropriado

Talvez um gráfico de linhas que mostra uma tendência no decorrer do tempo em vez de um gráfico de barras!




FIGURA 8.4 MUDE PARA UM GRÁFICO DE LINHAS

Guia prático em seis lições: Lição 2 - Escolha um visual apropriado

Representar todas as linhas no mesmo eixo **X** resolverá isso e também reduzirá a saturação e a redundância das várias legendas de ano.




FIGURA 8.5 GRÁFICO DE LINHAS ÚNICO PARA TODOS OS PRODUTOS

Guia prático em seis lições: Lição 3 - Elimine a saturação

1. Retirar a ênfase do título do gráfico.
2. Remover as bordas e as linhas da grade do gráfico.
3. Colocar as linhas e legendas dos eixos em segundo plano.
4. Remover a variação de cores entre as várias linhas.
5. Colocar a legenda nas linhas de forma direta.




FIGURA 8.5 GRÁFICO DE LINHAS ÚNICO PARA TODOS OS PRODUTOS

Guia prático em seis lições: Lição 3 - Elimine a saturação

Resultado:



FIGURA 8.6 ELIMINE A SATURAÇÃO

Guia prático em seis lições: Lição 4 - Foque a atenção onde você deseja

Considere a manchete inicial: *"O preço declinou para todos os produtos no mercado desde o lançamento do produto C, em 2010."*

Podemos modificá-la para: ***"Após o lançamento do produto C, em 2010, o preço médio no varejo dos produtos existentes declinaram."***




FIGURA 8.7 FOCALIZE A ATENÇÃO DO PÚBLICO

Guia prático em seis lições: Lição 4 - Foque a atenção onde você deseja

Considere a manchete inicial: *"O preço declinou para todos os produtos no mercado desde o lançamento do produto C, em 2010."*

Podemos modificá-la para: ***"Após o lançamento do produto C, em 2010, o preço médio no varejo dos produtos existentes declinaram."***




FIGURA 8.7 FOCALIZE A ATENÇÃO DO PÚBLICO

Guia prático em seis lições: Lição 4 - Foque a atenção onde você deseja

Concentrar a estratégia para outra observação:

*"Com o lançamento de um novo produto nessa área de atuação, é normal ver um **aumento** inicial no preço médio no varejo, seguido por um **declínio**."*





FIGURA 8.8 MUDE O FOCO DA ATENÇÃO DO PÚBLICO

Guia prático em seis lições: Lição 4 - Foque a atenção onde você deseja

Também pode ser interessante notar que:

*"Em 2014, os preços no varejo convergiram entre os produtos, com um **preço médio no varejo de \$223**, variando de um mínimo de \$180 (produto C) até um máximo de \$260 (produto A)."*



A cada visão diferente dos dados, o uso de atributos pré-atentivos permite ver certas coisas mais claramente.

Essa estratégia pode ser usada para realçar e contar diferentes partes de uma história com nuances.

FIGURA 8.9 MUDE NOVAMENTE O FOCO DA ATENÇÃO DO PÚBLICO

Guia prático em seis lições: Lição 5 - Pense como um designer

Pensar como designer:

"escolhemos um visual (forma) que permitirá ao nosso público fazer o que precisamos que faça (função) com facilidade."

Podemos melhorar ainda mais esse visual aproveitando lições relacionadas à acessibilidade e à estética:

1. **Tornar o visual acessível com o texto:** colocar um título mais simples e legendas nos eixos do gráfico.
2. **Alinhar elementos para melhorar a estética:** alinhar a legenda dos eixos e o título à esquerda (que antes está suspenso no espaço).

Guia prático em seis lições: Lição 5 - Pense como um designer

Resultado:




FIGURA 8.10 ADICIONE TEXTO E ALINHE OS ELEMENTOS

Guia prático em seis lições: Lição 5 - Pense como um designer

Resultado:




FIGURA 8.10 ADICIONE TEXTO E ALINHE OS ELEMENTOS

Guia prático em seis lições: Lição 6 - Conte uma história

Imagine que tenhamos cinco minutos em um ambiente de apresentação ao vivo, com o seguinte tópico:

“Panorama Competitivo - Fixação de Preço”.

Nosso **objetivo**:

1. Entender como os preços mudaram no decorrer do tempo no panorama competitivo.
2. Usar esse conhecimento para informar a fixação de preço de nosso produto.

Terminaremos com uma recomendação específica.

Guia prático em seis lições: Lição 6 - Conte uma história

Imagine que tenhamos cinco minutos em um ambiente de apresentação ao vivo, com o seguinte tópico:

“Panorama Competitivo - Fixação de Preço”.

Nosso **objetivo**:

1. Entender como os preços mudaram no decorrer do tempo no panorama competitivo.
2. Usar esse conhecimento para informar a fixação de preço de nosso produto.

Terminaremos com uma recomendação específica.

Guia prático em seis lições: Lição 6 - Conte uma história

Os produtos A e B foram lançados em 2008 com preços acima de US\$360.




FIGURA 8.12

Guia prático em seis lições: Lição 6 - Conte uma história

Eles tiveram preços semelhantes no decorrer do tempo, com B sistematicamente mais baixo do que A.




FIGURA 8.13

Guia prático em seis lições: Lição 6 - Conte uma história

Em 2014 os produtos A e B tinham preços US\$260 e US\$250, respectivamente.




FIGURA 8.14

Guia prático em seis lições: Lição 6 - Conte uma história

Os produtos C, D e E foram introduzidos depois com preços muito menores.



FIGURA 8.15

Guia prático em seis lições: Lição 6 - Conte uma história

... mas todos tiveram seus preços aumentados desde os seus lançamentos.




FIGURA 8.16

Guia prático em seis lições: Lição 6 - Conte uma história

Na verdade, com o lançamento de um novo produto nessa área de atuação, tendemos a ver um aumento no preço inicial, seguido de um decréscimo no decorrer do tempo.

Preço no varejo no decorrer do tempo




FIGURA 8.17

Guia prático em seis lições: Lição 6 - Conte uma história

Em 2014, os preços de varejo convergiram, com um preço médio de US\$223, variando de no mínimo US\$180 (produto C) até no máximo US\$ 260 (produto A).



FIGURA 8.18

Guia prático em seis lições: Lição 6 - Conte uma história

Para ser competitivo, recomenda-se a introdução do produto abaixo do preço médio de US\$223 na faixa entre US\$150 a US\$200.

Preço no varejo no decorrer do tempo




FIGURA 8.19

Guia prático em seis lições: Lição 6 - Conte uma história

Considerando a progressão:

1. *Começamos dizendo ao nosso público qual estrutura seguiríamos.*
2. *Podemos imaginar a narrativa da apresentação estabelecendo a trama:*
“Como todos sabem, cinco produtos serão nossos principais concorrentes no mercado...”
3. *Depois, construir o caminho cronológico de preços que os produtos seguiram.*
4. *Podemos introduzir tensão no panorama competitivo quando os produtos C, D e E baixaram significativamente.*
5. *Então, restaurar um senso de equilíbrio à medida que os preços convergem.*
6. *Terminamos com uma clara chamada para ação: a recomendação da fixação de preço de nosso produto.*

Chamando a atenção de nosso público para a parte específica da história que queremos focalizar o conduzimos pela história (narrativa).

Guia prático em seis lições

As seis lições importantes:

- **Lição 1:** Entenda o *contexto*.
- **Lição 2:** Escolha a *apresentação visual* adequada.
- **Lição 3:** Elimine a *saturação*.
- **Lição 4:** Foque a *atenção* onde você deseja.
- **Lição 5:** Pense como um *designer*.
- **Lição 6:** Conte uma *história*.

Guia prático em seis lições

E para o dataset do San Francisco Chronicle de 2003 a 2008, você consegue imaginar como aplicar as seis lições?



Bibliografia

[Bruce, Bruce & Gedek] Bruce, Peter; Bruce, Andrew; Gedeck, Peter. **Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python**. 2nd ed. California, USA: O'Reilly Media, 2020.

[Downey, 2025] Downey, Allen B.. **Think Stats: Exploratory Data Analysis**. California, USA: O'Reilly Media, 2025.

[Lau, Gonzalez & Nolan, 2023] Lau, Sam; Gonzalez, Joseph; Nolan, Deborah. **Learning Data Science: Data Wrangling, Exploration, Visualization, and Modeling with Python**. California, USA: O'Reilly Media, 2023.

[VanderPlas, 2016] VanderPlas, Jake. **Python Data Science Handbook: Essential Tools for Working with Data**. California, USA: O'Reilly Media, 2016.

[Knafllic, 2015] Knafllic, Cole Nussasbaumer. **Storytelling with Data: A Data Visualization Guide for Business Professionals**. Hoboken, Nova Jersey: Wiley, 2015.