



UFOP

Universidade Federal de Ouro Preto
Instituto de Ciências Exatas e Aplicadas



CDD105 - Estatística Descritiva e Visualização de Dados

Professor: Alexandre Magno de Sousa

Trabalho Prático

Aluno: Leonardo Isaac Silva Flores

Base de dados: *SF Bay Area Housing* (*sfhousing.txt*)

Recorte analisado: vendas registradas em 2005

Colab:

https://colab.research.google.com/drive/11yEerqlKnwapzKl_FbRDZQvPWBflkqVU?usp=sharing

1- Seleção da amostra

De acordo com o enunciado, deve ser feita a escolha de um único ano anterior a 2006. Foi selecionado 2005, o ano mais recente que atende a essa condição. A escolha permite trabalhar com um período próximo ao início da alta de preços mencionada no enunciado, sem afirmar que o mercado já estivesse estável. O recorte é feito em uma cópia do conjunto original, que permanece inalterado.

2- Carregamento e visão inicial da amostra

A base é carregada do arquivo *sfhousing.txt*, a coluna *date* é convertida para o tipo de data e, em seguida, são mantidas somente as vendas registradas em 2005. Para conferir o recorte, apresentam-se o número de registros da base completa, o tamanho e a proporção da amostra selecionada e suas cinco primeiras observações.

Dataset completo : 521,493 registros
Amostra de 2005 : 113,991 registros (21.9% do total)

	county	city	zip	street	price	br	lsqft	bsqft	year	date	datesold
0	Alameda County	Alameda	94501.00	1001 Santa Clara Avenue	880000.00	7.00	5914.00	3866.00	1995.00	2005-11-06	NaN
1	Alameda County	Alameda	94501.00	1001 Shoreline Drive \#201	570000.00	2.00	39353.00	1360.00	1970.00	2005-07-31	NaN
2	Alameda County	Alameda	94501.00	1001 Shoreline Drive \#204	525000.00	2.00	39353.00	1360.00	1970.00	2005-04-17	NaN
3	Alameda County	Alameda	94501.00	1001 Shoreline Drive \#208	535000.00	2.00	39353.00	1360.00	1970.00	2005-07-17	NaN
4	Alameda County	Alameda	94501.00	1001 Shoreline Drive \#307	515000.00	2.00	39353.00	1360.00	1970.00	2005-02-13	NaN

3- Atributos e suas Características

3a. Nomes, tipos

```
<class 'pandas.DataFrame'>
RangeIndex: 113991 entries, 0 to 113990
Data columns (total 11 columns):
#   Column      Non-Null Count  Dtype
---  -
0   county      113991 non-null  str
1   city         113991 non-null  str
2   zip          113983 non-null  float64
3   street       113991 non-null  str
4   price        113991 non-null  float64
5   br           91921 non-null   float64
6   lsqft        94160 non-null   float64
7   bsqft        96971 non-null   float64
8   year         93863 non-null   float64
9   date         113991 non-null  datetime64[us]
10  datesold     0 non-null       str
dtypes: datetime64[us](1), float64(6), str(4)
memory usage: 9.6 MB
```

3b. e natureza das variáveis

Tipo no arquivo		Natureza	Observação
county	Categórico	Nominal	Condado
city	Categórico	Nominal	Cidade
zip	Categórico	Nominal	Identificador postal
street	Texto	Nominal	Endereço
price	Numérico (float)	Quantitativo contínuo	Dólares
br	Numérico (float)	Quantitativo discreto	Contagem
lsqft	Numérico (float)	Quantitativo contínuo	Pés quadrados
bsqft	Numérico (float)	Quantitativo contínuo	Pés quadrados
year	Numérico (float)	Quantitativo discreto	Ano
date	Data	Temporal	Data da venda
datesold	Data	Temporal	Segunda data de venda

3c. Valores ausentes

3c. Valores ausentes

	ausentes	% ausentes
zip	8	0.01
br	22070	19.36
lsqft	19831	17.40
bsqft	17020	14.93
year	20128	17.66
datesold	113991	100.00

Tratamento dos valores ausentes: *datesold* não contém valores no recorte de 2005 e, por isso, não participa das análises. *br*, *lsqft*, *bsqft* e *year* apresentam, respectivamente, cerca de 19,36%, 17,40%, 14,93% e 17,66% de ausência. Em cada cálculo ou gráfico são usadas apenas as observações disponíveis para as variáveis envolvidas (*dropna*), sem eliminar linhas das demais análises. *zip* possui oito valores ausentes na amostra original. Esses registros são desconsiderados somente na análise geográfica. Não foi feita imputação, pois ela alteraria artificialmente as distribuições que se pretende descrever. Essa decisão reduz o número de observações em algumas análises e deve ser considerada na interpretação dos resultados.

3d. Ruído nos dados

Duplicidades segundo a chave informada no enunciado: 4 linhas envolvidas

	county	city	zip	street	price	br	lsqft	bsqft	year	date	datesold
61919	San Mateo County	Daly City	94015.00	370 Imperial Way	271000.00	NaN	NaN	483.00	1974.00	2005-10-16	NaN
61920	San Mateo County	Daly City	94015.00	370 Imperial Way	275000.00	NaN	NaN	483.00	1974.00	2005-10-16	NaN
82449	Santa Clara County	Morgan Hill	95037.00	585 Calle Buena Vista	594000.00	NaN	153767.00	NaN	NaN	2005-03-20	NaN
82452	Santa Clara County	Morgan Hill	95037.00	585 Calle Buena Vista	659000.00	NaN	153767.00	NaN	NaN	2005-03-20	NaN

Valores extremos antes da limpeza:

```
price  br    lsqft    bsqft    year
min  48000.00  1.00    19.00    122.00  1904.00
max 1000000.00 52.00 39204000.00 1856544.00 3860.00
ano fora de 1800-2005: 2 registro(s)
terreno acima de 500.000 pés²: 233 registro(s)
área construída acima de 20.000 pés²: 7 registro(s)
mais de 20 quartos: 5 registro(s)
```

Registros separados pelos critérios: 246 (0.22%)
Registros mantidos na análise : 113,745

Os extremos incluem dois anos de construção posteriores a 2005, 233 terrenos acima de 500 mil pés², sete áreas construídas acima de 20 mil pés² e cinco registros com mais de 20 quartos. Esses critérios separaram 246 linhas (0,22%) para evitar que possíveis erros de escala ou de registro dominassem os gráficos e as medidas. Os limites de área e de quartos são regras operacionais,

não provas de erro. Portanto, os registros originais foram preservados em *df_orig*, e uma análise voltada especificamente a propriedades rurais ou de luxo deveria reavaliá-los. As duas duplicidades encontradas segundo a chave indicada no enunciado também foram apenas apresentadas, pois as linhas não são cópias completas e podem representar correções ou registros distintos.

4- Variável-alvo

O problema proposto é de regressão, pois se pretende estimar um valor numérico. Variável dependente: *price*. Possíveis variáveis explicativas: *br*, *lsqft*, *bsqft*, *year*, *city*, *county* e componentes temporais derivados de *date*. *street* e *zip* são identificadores de localização e exigem codificação apropriada antes de entrar em um modelo. *datesold* não pode ser usada no recorte porque está vazia. A escolha definitiva das variáveis pertence à etapa de modelagem; aqui elas são apenas examinadas de forma exploratória.

5- Sumarização Estatística

A tabela abaixo reúne as principais medidas de tendência central, dispersão e forma para as variáveis numéricas.

	count	mean	50%	std	variance	cv	min	25%	75%	max	range	siqr	skewness	kurtosis
price	113745.00	679612.33	605000.00	372842.39	139011446559.50	0.55	48000.00	461000.00	779000.00	1000000.00	9952000.00	159000.00	3.85	34.03
br	91731.00	3.02	3.00	0.99	0.97	0.33	1.00	2.00	4.00	20.00	19.00	1.00	0.76	4.76
lsqft	93919.00	9609.33	5663.00	25965.12	674187277.27	2.70	19.00	3750.00	7700.00	499633.00	499614.00	1975.00	10.54	137.41
bsqft	96769.00	1595.46	1426.00	711.88	506771.28	0.45	122.00	1112.00	1894.00	12222.00	12100.00	391.00	1.85	6.64
year	93666.00	1966.07	1970.00	23.76	564.40	0.01	1904.00	1952.00	1985.00	2003.00	99.00	16.50	-0.67	-0.08


- Em *price*, a média (aproximadamente US\$ 680 mil) é superior à mediana (US\$ 605 mil), em concordância com a assimetria positiva. O CV de 0,55 indica dispersão considerável em relação à média.
- *lsqft* apresenta a maior dispersão relativa (CV de 2,70) e forte assimetria à direita. A curtose elevada indica caudas mais pesadas que as da distribuição normal e reforça a inspeção dos extremos.
- *br* é mais concentrada (CV de 0,33), com mediana de três quartos.

- *year* tem assimetria negativa (-0,67). Sua curtose próxima de zero, isoladamente, não permite concluir que inexistem observações atípicas.

Como *year* é uma marca temporal, o CV tem pouca utilidade substantiva para essa variável; ele foi mantido apenas para completar a tabela de medidas.

6- Distribuição das Variáveis

Histogramas com a curva normal teórica sobreposta. O título de cada gráfico traz os valores de *skewness* e *kurtosis* calculados.



Tipos de distribuição identificados:



Variável	Forma	Evidência
price	Right-skewed	skew = 3,85
br	Right-skewed leve	skew = 0,76
lsqft	Right-skewed extremo	skew = 10,54
bsqft	Right-skewed	skew = 1,85
year	Left-skewed leve	skew = -0,67

7- Outliers

Três formas de identificação: *kurtosis*, *boxplot* e gráfico de dispersão.

Curtose (valor positivo sugere caudas mais pesadas que a normal):

price	: $\kappa =$	34.03	inspecionar extremos
br	: $\kappa =$	4.76	inspecionar extremos
lsqft	: $\kappa =$	137.41	inspecionar extremos
bsqft	: $\kappa =$	6.64	inspecionar extremos
year	: $\kappa =$	-0.08	sem indicação por este critério




Interpretação dos valores atípicos

- O *boxplot* e o critério de $1,5 \times \text{IQR}$ identificam uma cauda superior extensa em *price*. Isso não significa que todas essas vendas sejam erros: imóveis de alto padrão fazem parte do mercado estudado.
- O corte de US\$ 4 milhões foi usado apenas para comparar a visualização com e sem a parte mais extrema da cauda. Uma eventual exclusão na modelagem dependeria do público-alvo do sistema e deveria ser avaliada por análise de sensibilidade.
- Valores extremos de *lsqft*, *bsqft* e *br* merecem conferência no cadastro. Valores pequenos de terreno também podem representar apartamentos ou particularidades do registro, e não erros automáticos.
- A curtose de *year* próxima de zero não substitui a verificação lógica; anos posteriores à data da venda foram tratados na etapa de ruído.

8- Estatística Descritiva vs. Gráficos

Os histogramas abaixo mostram a média (linha vermelha) e a mediana (linha verde) sobrepostas para cada variável





Nas variáveis com assimetria à direita (*price*, *lsqft*, *bsqft*, *br*), a média fica deslocada para a direita em relação à mediana – padrão já indicado numericamente na sumarização. Para *year*, as duas medidas ficam próximas, coerente com a assimetria leve.

Conforme o fluxograma do Resumo, para distribuições assimétricas a mediana é a medida de localização mais adequada, por não ser influenciada pelos extremos da cauda.

9- Relacionamento entre Variáveis

Gráficos de dispersão com e sem escala logarítmica para classificar o tipo de relação entre pares de variáveis.






Leitura dos gráficos com base na Tabela 2 do resumo:

Par	Escala em que o padrão ficou mais próximo de uma reta	Classificação exploratória
price × bsqft	$\log(\text{price}) \times \log(\text{bsqft})$	Log-Log
lsqft × bsqft	$\log(\text{lsqft}) \times \log(\text{bsqft})$	Log-Log
price × br	escala original	Aproximadamente linear, com grande dispersão
price × year	escala original	Sem relação evidente

10- Correlações: coeficientes de Pearson e *Spearman*. Conforme a Seção 3.7 do Resumo, Pearson é adequado para relações lineares; *Spearman*, para relações não lineares.



- $bsqft \times price$: *Spearman* = 0,66, correlação moderada segundo os limites do resumo.

- $br \times price$: *Spearman* = 0,47, correlação fraca.

- $lsqft \times price$: *Spearman* = 0,38, correlação fraca.

- $year \times price$: *Spearman* = -0,02, sem associação monotônica relevante no recorte.

Pearson descreve associação linear, enquanto *Spearman* descreve associação monotônica por postos. Nos pares cuja inspeção visual sugeriu curvatura, *Spearman* foi usado como complemento. A diferença mais visível ocorre em $lsqft \times price$ (0,38 em *Spearman* e 0,20 em Pearson). Correlação não implica causalidade e pode ser afetada por localização e outras variáveis omitidas.

11- Multicolinearidade

Identificação de pares com correlação forte ($|\rho| > 0,75$) entre variáveis independentes. Pares fortemente correlacionados precisam de tratamento para evitar multicolinearidade.

Pares de variáveis explicativas com $|\text{correlação}| > 0,75$:

```

--- Pearson ---
br      x lsqft   : r=+0.03  fraca ou moderada
br      x bsqft   : r=+0.67  fraca ou moderada
br      x year    : r=+0.12  fraca ou moderada
lsqft   x bsqft   : r=+0.15  fraca ou moderada
lsqft   x year    : r=+0.04  fraca ou moderada
bsqft   x year    : r=+0.16  fraca ou moderada

--- Spearman ---
br      x lsqft   : r=+0.37  fraca ou moderada
br      x bsqft   : r=+0.71  fraca ou moderada
br      x year    : r=+0.14  fraca ou moderada
lsqft   x bsqft   : r=+0.40  fraca ou moderada
lsqft   x year    : r=-0.01  fraca ou moderada
bsqft   x year    : r=+0.23  fraca ou moderada


```

Nenhum par numérico ultrapassou o limite de 0,75 adotado no resumo.

Nenhum par das variáveis numéricas explicativas ultrapassa $|r| = 0,75$ em Pearson ou *Spearman*. Portanto, não foi encontrada correlação par a par forte por esse critério. Isso não prova ausência completa de multicolinearidade: a confirmação, na etapa de modelagem, pode incluir VIF e análise conjunta das variáveis codificadas. A correlação entre *bsqft* e *price* não é motivo para remover *bsqft*, pois envolve uma variável explicativa e o alvo. A verificação desta seção não inclui *city*, *county* e *zip*, que são categóricas e exigem outras formas de codificação e associação.

12- Transformações Promissoras:

Para variáveis *right-skewed*, o Resumo recomenda transformação logarítmica (base 10). Abaixo, apresenta-se a comparação da distribuição original e da transformada para as três variáveis afetadas.



Transformações promissoras com base na Tabela 3 do resumo:

Variável	Forma observada	Alternativa	Assimetria após a transformação
price	Assimetria à direita	log10	0,42
lsqft	Assimetria acentuada à direita	log10	0,33
bsqft	Assimetria à direita	log10	0,29
br	Assimetria leve à direita	manter inicialmente	0,76
year	Assimetria à esquerda	manter inicialmente	-0,67

A transformação log10 reduziu a assimetria das três variáveis e, por isso, é uma alternativa promissora para experimentos posteriores. Em regressão linear, a hipótese de normalidade se refere principalmente aos resíduos condicionais, não à variável-alvo isoladamente. Assim, a decisão de transformar *price* deve ser confirmada pelos diagnósticos do modelo e pela interpretação desejada dos coeficientes.

13- Dados Adicionais Úteis

Informações que poderiam melhorar a capacidade preditiva do modelo:

1. Avaliação de escolas por bairro — qualidade das escolas públicas tem impacto direto nos preços em São Francisco.
2. Distância ao centro financeiro — proximidade a hubs de emprego é um dos principais drivers de preço.
3. Estado de conservação do imóvel — ausente no *dataset*; explica boa parte da variação dentro de um mesmo CEP.
4. Número de banheiros e vagas de garagem — features padrão em modelos de precificação imobiliária.
5. Índice de crime por bairro — influencia diretamente a valorização em grandes metrópoles americanas.

14- Síntese da análise

Qualidade dos dados:

O recorte contém 113.991 vendas de 2005 e 113.745 registros após a aplicação dos critérios operacionais de plausibilidade. Há ausência relevante em *br*, *lsqft*, *bsqft* e *year*, além de duas duplicidades segundo a chave declarada no enunciado. Essas duplicidades não foram eliminadas automaticamente porque não são cópias completas.

Distribuições:

price, *lsqft* e *bsqft* apresentam assimetria à direita. A transformação logarítmica reduz essa assimetria, mas sua adoção deve ser confirmada na etapa de modelagem. *year* apresenta assimetria negativa moderada.

Valores atípicos:

Os gráficos mostram caudas e observações extremas, especialmente em preço e áreas. Parte delas pode representar imóveis reais de alto padrão. Por isso, o corte de US\$ 4 milhões foi usado somente como comparação visual, e não como exclusão definitiva.

Relacionamentos:

bsqft apresenta a maior associação com *price* entre as variáveis numéricas avaliadas (*Spearman* = 0,66). *year* praticamente não apresenta associação monotônica com o preço neste recorte. Localização e possíveis variáveis omitidas devem ser consideradas antes de interpretar essas relações.

Correlação entre explicativas:

Nenhum par numérico ultrapassou $|r| = 0,75$. Esse resultado não indica correlação par a par forte pelo critério do resumo, mas não substitui diagnósticos de multicolinearidade durante a modelagem.

15- Exercício Extra – Mapa de Imóveis por CEP

Os CEPs presentes nos dados de 2005 são convertidos em coordenadas geográficas e representados em duas camadas: mapa de calor do volume de vendas e preço mediano por CEP. As duas camadas são apresentadas lado a lado; na versão HTML, o controle no canto superior direito permite ativar ou ocultar cada camada. O arquivo `mapa_imoveis_2005.html` preserva todos os recursos interativos, incluindo seleção de camadas, zoom, deslocamento, dicas e detalhes por CEP.


CEPs únicos: 288
Registros sem CEP: 7


	zip_str	vendas	preco_mediano	preco_medio
78	94513	2266	620000.00	630077.01
118	94565	2014	435000.00	462753.23
92	94533	1734	420000.00	440777.10
75	94509	1587	430000.00	440081.31
138	94591	1380	509000.00	523181.88
234	95123	1353	585000.00	551948.63
284	95687	1338	431000.00	460341.18
130	94582	1325	948000.00	956532.08
121	94568	1287	615000.00	737649.57
91	94531	1233	552000.00	570820.36

Base GeoNames carregada do cache: 41,490 registros

CEPs geocodificados: 287 / 288

	zip_str	place	state_code	lat	lon	vendas	preco_mediano
0	94002	Belmont	CA	37.52	-122.29	350	860000.00
1	94005	Brisbane	CA	37.68	-122.40	95	650000.00
2	94010	Burlingame	CA	37.57	-122.37	490	1350000.00
3	94014	Daly City	CA	37.69	-122.44	422	669500.00
4	94015	Daly City	CA	37.68	-122.48	608	683500.00





Referências:

1. LAU, Sam; GONZALEZ, Joey; NOLAN, Deb. Learning Data Science. Sebastopol: O'Reilly Media, 2023. Base sfhousing.csv e exemplo “Sale Prices for Houses”. Disponível em: https://learningds.org/ch/10/eda_example.html. Acesso em: 24 jul. 2026.
2. LAU, Sam; GONZALEZ, Joey; NOLAN, Deb. SF Bay Area Housing (sfhousing.csv). Repositório do livro Learning Data Science. Dados originalmente coletados das páginas imobiliárias do San Francisco Chronicle. Disponível em: <https://github.com/DS-100/textbook/tree/master/content/datasets>. Acesso em: 24 jul. 2026.
3. SOUSA, Alexandre Magno de. Resumo — Estatística Descritiva e Visualização de Dados. Material da disciplina CDD105, Universidade Federal de Ouro Preto, 2026.
4. OPENAI Codex AI – Prompts utilizados: “validar resolução do Trabalho Prático e destacar equívocos” e “converter CEPs em latitude/longitude e gerar mapa a partir da seleção dos CEPs da base estudada”. Consultado em: 29 jul. 2026.