



TRABALHO PRÁTICO

Curso: Especialização em Ciência de Dados

1º semestre de 2026

Disciplina: Estatística Descritiva e Visualização de Dados

Data: 04/07/26

Professor: Alexandre Magno de Sousa

Data de entrega: 18/07/26

1. O conjunto de dados foi extraído do site do [San Francisco Chronicle](#), que compreende um registro completo de imóveis residenciais vendidos na região da cidade de São Francisco, Califórnia, Estados Unidos, entre abril de 2003 e dezembro de 2008. Quanto à granularidade, cada registro representa a venda de uma casa na região da Baía de São Francisco durante o período especificado. Isso significa que, se uma casa foi vendida duas vezes nesse intervalo, haverá dois registros na tabela, a saber, `date` e `datesold`. Por outro lado, se uma casa na região da Baía não foi colocada à venda durante esse período, ela não aparecerá no conjunto de dados. A Tabela 1 apresenta o dicionário de dados desse conjunto de dados.

Tabela 1: Dicionário de dados.

Feature	Descrição	Tipo	Exemplo
county	Condado do imóvel.	Categórico	San Francisco County
city	Cidade do imóvel.	Categórico	San Francisco
zip	Código postal dos Estados Unidos.	Numérico	94100
street	Endereço do imóvel.	Categórico	180 Haight Street
price	Preço de venda do imóvel em dólares.	Numérico	595000
br	Número de quartos do imóvel.	Numérico	6
lsqft	Área do terreno em pés quadrados.	Numérico	2297
bsqft	Área construída em pés quadrados.	Numérico	4875
year	Ano de construção do imóvel.	Numérico	1990
date	Data de venda do imóvel.	Categórico	2005-11-13
datesold	Segunda data de venda do imóvel.	Categórico	NA

Com base nos nomes dos campos, achave primária¹ consiste na combinação das *features* cidade (`city`), código postal (`zip`), endereço (`street`) e data (`date`).

Nosso objetivo é iniciar um projeto de Ciência de Dados que consiste na criação de uma solução para um problema de regressão, onde pretende-se prever o preço de venda do imóvel (i.e. `price`) dado um conjunto de indicadores. Portanto, o preço de venda é nossa variável a ser predita (variável dependente) e as demais *features* são as variáveis preditoras (variáveis independentes).

A ideia é que a saída da solução deste projeto seja uma entrada para um sistema de análise de investimentos da imobiliária Sotheby's International Realty antes da bolha imobiliária estourar em 2008. O processo iniciou-se com uma forte alta e supervalorização dos preços dos imóveis até o início de 2006. A bolha estourou quando o mercado de hipotecas de alto risco entrou em colapso e os preços despencaram, culminando na crise financeira global que ficou marcada pela falência do Lehman Brothers em setembro de 2008. Por isso, a análise exploratória deve ser feita apenas para um ano antes do início da bolha imobiliária. Portanto, você deverá selecionar uma amostra do conjunto de dados proveniente de um único ano antes do início da supervalorização de preços, isto é, antes de 2006.

Diante desse cenário, para iniciar o projeto, seu papel é realizar a análise exploratória de dados aplicando as técnicas de estatística descritiva e visualização de dados.

¹Chave primária é o atributo ou conjunto de atributos que identifica uma observação de forma única.